



Universidad Internacional de La Rioja
Facultad de Ciencias de la Salud

Máster Universitario en Bioinformática

**Integración de datos clínicos, genómicos
y transcriptómicos mediante aprendizaje
automático para la predicción de
supervivencia en cáncer de mama**

Trabajo fin de Estudio presentado por:	María Dunia Roldán Díaz
Tipo de trabajo:	Análisis de datos (Tipo 3)
Director/a:	Víctor J. Fernández
Fecha:	09/09/2026

Resumen

El cáncer de mama es la neoplasia maligna más frecuente en mujeres a nivel mundial y se caracteriza por una profunda heterogeneidad que dificulta la predicción del pronóstico. Los avances en las tecnologías de secuenciación de nueva generación y la disponibilidad de grandes cohortes de datos multi-ómicos ofrecen la oportunidad de desarrollar modelos predictivos más precisos mediante el uso de técnicas de aprendizaje automático. En este trabajo se entrenaron y compararon tres algoritmos de aprendizaje automático –SVM con kernel lineal, SVM con kernel radial y *Random Forest*– para la predicción de la mortalidad a tres años en pacientes con cáncer de mama, utilizando datos transcriptómicos y de mutaciones somáticas procedentes de la cohorte TCGA-BRCA, tanto de forma independiente como integrada mediante una estrategia de fusión temprana. Los modelos basados únicamente en datos mutacionales mostraron una sensibilidad nula en el conjunto de prueba. Los modelos basados en expresión génica mostraron un AUC máximo para el SVM radial de 0,663. La integración de ambas modalidades produjo un AUC de 0,671 con este mismo algoritmo, sin evidenciar una mejora clara respecto a la expresión aislada. Los resultados sugieren que, en la cohorte analizada, la estrategia de integración empleada no aportó una mejora consistente del rendimiento.

Palabras clave: cáncer de mama, aprendizaje automático, supervivencia

Abstract

Breast cancer is the most common malignancy among women worldwide and is characterized by significant heterogeneity, which makes it difficult to predict the prognosis. Advances in next-generation sequencing technologies and the availability of large multi-omic datasets provide an opportunity to develop more accurate predictive models using machine learning techniques. In this study, three machine learning techniques -linear kernel SVM, radial kernel SVM and Random Forest- were trained and compared to predict three-year mortality in breast cancer patients, using transcriptomic and somatic mutation data from the TCGA-BRCA cohort, both independently and in an integrated early fusion approach. Models based solely on mutational data exhibited zero sensitivity in the test set. Gene expression-based models achieved a maximum AUC of 0.663 using a radial basis function SVM. The integration of both modalities yielded an AUC of 0.671 with the same algorithm, without showing clear improvement over transcriptomic data alone. These findings suggest that, within the analysed cohort, the employed integration strategy did not consistently enhance predictive performance.

Keywords: breast cancer, machine learning, survival

Índice de contenidos

1. Introducción	9
2. Marco teórico.....	11
2.1. Aspectos generales del cáncer de mama	11
2.2. Subtipos de cáncer de mama.....	12
2.3. Bases moleculares del cáncer de mama.....	15
2.3.1. Vía de los receptores hormonales (ER/PR).....	16
2.3.2. Vía HER2/ERBB2	17
2.3.3. Vía PI3K/AKT	17
2.4. Progresión del cáncer de mama. Metástasis y factores pronósticos	17
2.5. Ciencias ómicas en cáncer de mama	20
2.5.1. Genómica.....	21
2.5.2. Transcriptómica	21
2.5.3. Proyectos colaborativos para la caracterización molecular del cáncer	22
2.6. Aprendizaje automático y sus aplicaciones en oncología	23
2.6.1. Aprendizaje automático para la predicción pronóstica en cáncer de mama	25
3. Hipótesis y objetivos	27
4. Material y métodos	29
4.1. Entorno computacional	29
4.2. Obtención de datos y preprocesamiento inicial.....	29
4.3. Exploración de datos clínicos y definición de la variable respuesta.....	30
4.4. Preprocesamiento y análisis exploratorio	31
4.4.1. Datos de expresión génica.....	31
4.4.2. Datos de mutaciones somáticas.....	32
4.5. Selección de variables y construcción de los modelos predictivos	32
4.5.1. Selección de genes diferencialmente expresados	34
4.5.2. Selección de variables mutacionales.....	34
4.5.3. Integración ómica	35
4.6. Entrenamiento y evaluación de los modelos predictivos.....	36

5. Resultados	38
5.1. Descripción de la cohorte	38
5.1.1. Cohorte incluida en la clasificación de riesgo	40
5.2. Exploración de la expresión génica.....	42
5.3. Caracterización de las mutaciones somáticas	44
5.4. Selección de variables.....	46
5.4.1. Genes diferencialmente expresados entre grupos de riesgo	46
5.4.2. Variables mutacionales seleccionadas	49
5.5. Evaluación de los modelos predictivos.....	50
5.5.1. Modelos entrenados sobre los datos de expresión génica.....	50
5.5.2. Modelos entrenados sobre los datos de mutaciones somáticas	51
5.5.3. Modelos entrenados sobre la matriz integrada	52
6. Discusión	54
7. Conclusiones.....	59
8. Limitaciones del estudio.....	61
Referencias bibliográficas.....	63

Índice de figuras

Figura 1. Estructura de la mama (A) y progresión del tumor mamario de in situ a invasivo (B).....	11
Figura 2. Subtipos de cáncer de mama.	13
Figura 3. Perfil transcriptómico de genes clave en los subtipos intrínsecos de cáncer de mama para muestras de TCGA (n=792)..	14
Figura 4. Principales vías de señalización en cáncer de mama.	16
Figura 5. Aplicaciones de la inteligencia artificial en oncología de precisión..	23
Figura 6. Diagrama de flujo general del Trabajo Fin de Máster.....	28
Figura 7. Diagrama de flujo de los análisis exploratorios y selección de variables para cada modalidad ómica.	33
Figura 8. Caracterización clínica y molecular de la cohorte TCGA-BRCA (n=965).....	38
Figura 9. Distribución del tiempo de seguimiento en los pacientes vivos.	39
Figura 10. Distribución del tiempo hasta el fallecimiento en pacientes fallecidos.....	40
Figura 11. Distribución de la edad al diagnóstico según el grupo de riesgo (n=444).	40
Figura 12. Distribución del subtipo molecular (A) y estadio (B) según el grupo de riesgo. .	41
Figura 13. Análisis de componentes principales de los perfiles de expresión génica.....	42
Figura 14. Mapa de calor de la expresión génica para los 1 000 genes más variables.....	43
Figura 15. Gráfico resumen de las mutaciones somáticas identificadas en la cohorte (n=444).	44
Figura 16. Paisaje mutacional de los 10 genes más frecuentemente mutados en la cohorte.	45

Figura 17. Diagrama de volcán del análisis de expresión diferencial entre los grupos de Alto y Bajo riesgo en el conjunto de entrenamiento.....	47
Figura 18. Mapa de calor de los 50 genes diferencialmente expresados con mayor significancia estadística en el conjunto de entrenamiento.....	47
Figura 19. Gráfico de enriquecimiento GSEA para los 15 procesos Hallmark más significativos.	48
Figura 20. Curvas ROC de los modelos predictivos entrenados sobre datos de expresión génica.....	51
Figura 21. Curvas ROC de los modelos predictivos entrenados sobre datos de vías KEGG alteradas.	52
Figura 22. Curvas ROC de los modelos predictivos entrenados sobre la matriz integrada.	53

Índice de tablas

Tabla 1. Algunos factores pronósticos en cáncer de mama.....	19
Tabla 2. Tamaño de los conjuntos de datos empleados en el estudio.	30
Tabla 3. Número de pacientes clasificables según el horizonte temporal de supervivencia.	31
Tabla 4. Vías metabólicas y de señalización KEGG seleccionadas mediante regresión LASSO en el conjunto de entrenamiento.	49
Tabla 5. Rendimiento de los modelos predictivos entrenados con datos de expresión génica.	50
Tabla 6. Rendimiento de los modelos predictivos entrenados con datos de mutaciones somáticas agrupados por vía KEGG.	51
Tabla 7. Rendimiento de los modelos predictivos entrenados con la matriz integrada.....	53

1. Introducción

El cáncer de mama constituye una de las neoplasias malignas más frecuentes y una de las principales causas de mortalidad por cáncer en mujeres a nivel mundial. Con más de 2,3 millones de casos diagnosticados anualmente, representa el 11,6% de todos los cánceres diagnosticados globalmente, situándose como el segundo cáncer más frecuente en la población, sólo por detrás del cáncer de pulmón. Considerando exclusivamente a la población femenina, supone el 23,8% de los diagnósticos oncológicos, situándose como el cáncer más común en este sexo, y es responsable del 15,4% de las muertes por cáncer (1). La incidencia de esta enfermedad continúa aumentando, por tanto, el cáncer de mama constituye un importante problema de salud pública.

Gracias a los avances en detección precoz y al desarrollo de tratamientos más eficaces, el cáncer de mama es curable en el 70-80% de los casos cuando se diagnostica en estadio localizado (2). Sin embargo, una proporción significativa experimenta recurrencia o progresión de la enfermedad, para la que las opciones terapéuticas actuales se centran sólo en alargar la vida del paciente. Por ello, la predicción del pronóstico es uno de los grandes desafíos de la oncología moderna.

Uno de los factores que dificulta esta predicción es la profunda heterogeneidad biológica del cáncer de mama. Lejos de ser una entidad uniforme, comprende múltiples subtipos moleculares con comportamientos clínicos, patrones de recurrencia y respuestas terapéuticas distintas. A diferencia de otros tumores sólidos, el cáncer de mama se caracteriza además por presentar una amplia ventana de recaída, que puede abarcar desde meses hasta décadas tras el diagnóstico inicial (3). La información clínico-patológica derivada del paciente y el tumor primario se han utilizado para construir modelos pronósticos, sin embargo, ofrecen una visión parcial de la complejidad del tumor, lo que dificulta identificar a las pacientes en mayor riesgo y la selección del tratamiento más adecuado para cada una.

El desarrollo de las tecnologías de secuenciación masiva y otras aproximaciones ómicas ha permitido caracterizar de manera exhaustiva las alteraciones moleculares presentes en los tumores. Estas herramientas han facilitado la identificación de biomarcadores asociados a la progresión tumoral, la respuesta terapéutica y pronóstico clínico. En particular, la disponibilidad de grandes cohortes multi-ómicas abre la posibilidad de construir modelos predictivos que capturen de forma más completa la heterogeneidad molecular del tumor y sus implicaciones pronósticas.

Paralelamente, el auge de la inteligencia artificial (IA) en los últimos años y su aplicación en la investigación clínica ha alcanzado nuevos niveles en la predicción de cáncer. Las técnicas de IA como el aprendizaje automático (AA, en inglés *machine learning*, ML) son capaces de identificar patrones complejos y relaciones no lineales en grandes conjuntos de datos biológicos, permitiendo desarrollar modelos predictivos ajustados al perfil molecular de cada paciente (4).

En este contexto, el presente trabajo evalúa el potencial de la integración ómica para la predicción pronóstica en cáncer de mama. Para ello, se emplearon datos clínicos, genómicos y transcriptómicos procedentes de pacientes del proyecto *The Cancer Genome Atlas* (TCGA) con el objetivo de entrenar y comparar algoritmos de aprendizaje automático para la predicción de supervivencia a 3 años, basados tanto en cada capa de información por separado como en combinación. La hipótesis de partida es que la integración multi-ómica permitirá capturar de manera más completa la heterogeneidad biológica del tumor y mejorar la capacidad de estratificación de riesgo respecto a los modelos construidos a partir de una única fuente de información.

2. Marco teórico

2.1. Aspectos generales del cáncer de mama

La Sociedad Española de Oncología Médica (SEOM) define el cáncer como *“un grupo numeroso de enfermedades que se caracterizan por el desarrollo de células anormales, que se dividen, crecen y se diseminan sin control en cualquier parte del cuerpo”*. Estas células tumorales se originan como consecuencia de la acumulación de alteraciones genéticas y epigenéticas que afectan a los mecanismos responsables del control del ciclo celular, la reparación del daño en el ADN y la apoptosis, favoreciendo así una proliferación celular desregulada (5).




Figura 1. Estructura de la mama (A) y progresión del tumor mamario de in situ a invasivo (B). Obtenida de (6).

El cáncer de mama se origina a partir del tejido epitelial de la glándula mamaria. La mama es un órgano con una estructura túbulo-alveolar altamente ramificada, constituida por los lóbulos mamarios, responsables de la producción de leche, y los conductos galactóforos encargados de transportarla hasta el pezón. La red ductal consiste en una bicapa de células epiteliales luminales y mioepiteliales, rodeadas por un estroma de adipocitos, fibroblastos

y células inmunitarias que proporcionan soporte estructural y funcional (Figura 1A) (7). La mayor parte de los cánceres de mama surgen a partir de la unidad ductal lobulillar terminal (TDLU, por sus siglas en inglés), principal unidad funcional de la glándula mamaria (2,6).

2.2. Subtipos de cáncer de mama

El cáncer de mama comprende un conjunto de enfermedades muy heterogéneas, debido principalmente a diferencias en las características genómicas, epigenómicas, transcriptómicas y proteómicas de las células tumorales. Esta heterogeneidad influye de manera directa en la evolución de la enfermedad, el pronóstico de las pacientes y la respuesta a los distintos tratamientos (8). Debido a ello, se han desarrollado diferentes sistemas de clasificación basados en las características histopatológicas y moleculares de los tumores mamarios, con el objetivo de mejorar la estratificación clínica y seleccionar las estrategias terapéuticas más adecuadas.

La gran mayoría de los casos de cáncer de mama son de origen epitelial, lo que histológicamente corresponde a carcinomas (9). En el momento del diagnóstico, los tumores mamarios pueden clasificarse histológicamente como carcinomas *in situ* o invasivos, en función de la diseminación de las células tumorales desde los lóbulos o conductos hacia el estroma circundante (Figura 1B) (6).

Los carcinomas invasivos se pueden subdividir aún más según su morfología celular en los llamados “subtipos histológicos especiales”, llegando a encontrar hasta 18 subtipos con presentaciones clínicas distintas (10). No obstante, el carcinoma ductal invasivo (CDI) de tipo no especial constituye el subtipo más común de cáncer de mama, representando hasta el 80% de todos los casos, seguido del carcinoma lobular invasivo (CLI) (9). Sus lesiones precursoras no invasivas se corresponden con el carcinoma ductal *in situ* (CDIS) y el carcinoma lobular *in situ* (CLIS), respectivamente (2,6). El CDI y el CLI presentan diferencias significativas tanto a nivel histopatológico como molecular, tanto que son considerados enfermedades distintas. Ambos muestran perfiles genómicos, patrones de diseminación metastásica y respuestas a tratamientos diferentes (6,9).

Hoy en día, la clasificación comúnmente usada en la clínica, y crucial para dirigir el tratamiento, se basa en la expresión de tres proteínas clave tras la tinción inmunohistoquímica del tumor (Figura 2). Estas son el receptor de estrógeno (ER, del inglés *estrogen receptor*), el receptor de progesterona (PR, del inglés *progesterone receptor*) y el receptor 2 del factor de crecimiento epidérmico humano (HER2 o *ERBB2*, del inglés *human epidermal growth factor receptor 2* y *Erb-b2 receptor tyrosine kinase 2*). De esta forma, el cáncer de mama se divide en 3 grandes grupos: ER positivo (ER+) y/o PR positivo (PR+), que expresan alguno de los 2 receptores hormonales mencionados; HER2+, con sobreexpresión de dicha proteína; y triple negativo (TNBC, del inglés *triple negative breast cancer*), este último careciendo de los 3 tipos de receptores de membrana y asociado a un peor pronóstico de la enfermedad (6).




Figura 2. Subtipos de cáncer de mama. Modificada de (2).

Con la llegada de los análisis transcriptómicos surgieron nuevas clasificaciones basadas en estudios de expresión génica, dividiendo al cáncer de mama en 5 subtipos intrínsecos basados en la firma de expresión de 50 genes (PAM50) (Figura 3) (11). Estos son Luminal A, Luminal B, HER2-enriquecido, Basal y de Tipo Normal, que captan gran parte de la heterogeneidad molecular del cáncer de mama. Los tumores Luminal A son hormonopositivos (ER+, PR+), presentan una sólida expresión de genes asociados al linaje luminal (*ESR1*, *GATA3*, *XBP1*, *FOXA1*) y una menor expresión de genes relacionados con la proliferación y el ciclo celular. Por su parte, los tumores Luminal B son también ER+, pero se caracterizan por una mayor expresión de genes de proliferación (como *MKI67* y *AURKA*) y una baja expresión del gen receptor de progesterona (*PGR*) (12–14).




Figura 3. Perfil transcriptómico de genes clave en los subtipos intrínsecos de cáncer de mama para muestras de TCGA (n=792). Obtenida de (14).

Los tumores HER2-enriquecidos se distinguen por la amplificación de genes situados en la región 17q12, que incluye *HER2/ERBB2* y genes vecinos como *GRB7*, asociados a la señalización mediada por receptores tirosina-quinasa y a la proliferación. Además,

muestran una escasa expresión de la firma luminal. El subtipo Basal se asocia a un patrón de “célula basal/mioepitelial”, con baja expresión de *ESR1/PGR/ERBB2* y alta expresión de genes de citoqueratinas, lamininas y otros marcadores proliferativos (*KRT5/6A*, *ID4* y *FOXC1*) siendo el núcleo biológico de gran parte de los tumores triple negativos (6,12,14).

Por último, el cáncer de mama de tipo Normal se considera a menudo un artefacto, ya que presenta alta contaminación por células normales adyacentes debido a la baja celularidad del tumor (2). Este subtipo presenta una alta expresión en genes del tejido adiposo y otros tejidos no epiteliales. También suelen mostrar una fuerte expresión de la firma basal y menor en genes luminales (15).

2.3. Bases moleculares del cáncer de mama

El cáncer de mama es una enfermedad impulsada por alteraciones en la secuencia del ADN que, si bien pueden heredarse a través de la línea germinal -como es el caso de las conocidas mutaciones en *BRCA1/2* -, surgen en la mayoría de los casos de forma somática a lo largo de la vida del paciente (16). Dichas alteraciones comprometen vías de señalización clave como la proliferación, la reparación del ADN y el control del ciclo celular, sentando las bases moleculares del desarrollo tumoral.

Gracias a los estudios de secuenciación del genoma se han identificado genes recurrentemente mutados en cáncer de mama. Algunos de los más frecuentes son *TP53*, *PIK3CA*, *GATA3*, *CDH1*, *ERBB2* y *PTEN* (13,16). Estas alteraciones convergen en la desregulación del equilibrio entre proliferación y muerte celular, ya sea mediante la inactivación de supresores tumorales como *TP53* o *PTEN*, o la sobreactivación de oncogenes como *ERBB2* (2). Conocer estos genes y vías de señalización significa identificar posibles biomarcadores de la enfermedad y dianas terapéuticas. Las tres vías más relevantes en cáncer de mama son la vía de los receptores hormonales, la señalización por HER2 y la vía PI3K/AKT/mTOR (Figura 4).




Figura 4. Principales vías de señalización en cáncer de mama. En la parte inferior se indica la frecuencia de mutación para 20 genes clave en cada subtipo. Los datos se obtuvieron del análisis del conjunto de datos PanCancer (n=1066) de cBioPortal. Obtenida de (6).

2.3.1. Vía de los receptores hormonales (ER/PR)

Aproximadamente dos tercios de los cánceres de mama expresan receptores de estrógenos (ER) y/o progesterona (PR) (6). En estos subtipos, la señalización estrogénica es el principal impulsor del crecimiento tumoral: el estrógeno se une al receptor ERα (codificado por el gen *ESR1*), que actúa como factor de transcripción activando genes implicados en proliferación y supervivencia celular (9). Asimismo, ERα puede interactuar con cofactores

transcripcionales como GATA3 y FOXA1. Por todo esto, uno de los mayores factores de riesgo del cáncer de mama esporádico se asocia al incremento en la exposición a las hormonas esteroideas ováricas, como ocurre durante los ciclos menstruales, el embarazo o la menopausia (2).

2.3.2. Vía HER2/ERBB2

HER2 es un receptor tirosina quinasa de la familia ERBB. Su amplificación o sobreexpresión, presente en torno al 15-20% de los tumores mamarios, desencadena la activación de vías de señalización como RAS/MAPK, PI3K/AKT/mTOR y ciclina D1/CDK4/6, promoviendo la proliferación, supervivencia e invasión tumoral (6,9). Los tumores HER2-positivos se asocian históricamente a peor pronóstico, aunque la incorporación de terapias dirigidas anti-HER2 ha transformado significativamente su evolución clínica.

2.3.3. Vía PI3K/AKT

Es la vía de señalización intracelular más frecuentemente alterada en cáncer de mama. La fosfatidilinositol-3-quinasa (PI3K) regula procesos como la proliferación, supervivencia, invasión, migración, apoptosis y metabolismo celular a través de la activación de AKT y mTOR. Se han descrito mutaciones somáticas tanto en *PIK3CA* como en numerosos componentes de la vía (como *PTEN*) (2). Existe además un diálogo cruzado con la señalización estrogénica: la activación de la vía PI3K/AKT/mTOR puede inducir actividad transcripcional del receptor ER α de forma independiente de ligando, constituyendo uno de los mecanismos centrales de resistencia a la terapia endocrina (6).

2.4. Progresión del cáncer de mama. Metástasis y factores pronósticos

Los tumores mamarios poseen capacidad metastásica y pueden diseminarse a otros órganos, incluyendo ganglios linfáticos axilares y localizaciones distantes como hueso, pulmón, hígado o cerebro (3,9,17). En estos casos, la enfermedad se denomina cáncer de mama metastásico, considerado una forma avanzada de la enfermedad. Este puede detectarse en el momento del diagnóstico inicial, denominado cáncer metastásico *de novo*,

o aparecer como consecuencia de una recaída (recurrencia) meses o años después del tratamiento para el tumor primario, siendo esta última la forma más frecuente (3,9). Aproximadamente el 30% de pacientes con cáncer de mama experimentan recurrencia metastásica, la cual continúa siendo actualmente incurable (2).

Los mecanismos biológicos que determinan el desarrollo de metástasis en cáncer de mama no se conocen completamente, ya que dependen tanto de las características intrínsecas del tumor como de factores ambientales y del huésped (3). Por ello, la predicción del riesgo de recurrencia metastásica en cada paciente supone un gran desafío.

Entre los principales factores pronósticos clásicos asociados al riesgo de diseminación metastásica se encuentran el tamaño del tumor primario, el estadio de la enfermedad, la afectación de los ganglios linfáticos axilares, el grado histológico, el índice de proliferación Ki-67, el estado de los receptores hormonales (ER/PR) y la sobreexpresión de HER2 (17). Conocer estos parámetros es de gran utilidad para identificar pacientes con alto riesgo de metástasis y seleccionar el tratamiento más adecuado. Sin embargo, estos factores clínico-patológicos presentan limitaciones a la hora de capturar la extensa heterogeneidad molecular del cáncer, conduciendo a sesgos en la predicción del riesgo entre tumores con características similares (18).

Con la llegada de las firmas génicas, muchos países occidentales han incorporado en el pronóstico paneles de expresión génica, como es el caso de PAM50, que asigna los subtipos intrínsecos vistos anteriormente y un riesgo de recurrencia (ROR, del inglés, *risk of recurrence*) (18) (Tabla 1). En general, el subtipo luminal A se asocia a un bajo riesgo de recurrencia distante, siendo aquel con mejor pronóstico. Por el contrario, los tumores luminal B presentan un riesgo significativamente mayor. Los tumores HER2-enriquecidos y basales tienden a ser más proliferativos y se asocian a un peor pronóstico (19).

Tabla 1. Algunos factores pronósticos en cáncer de mama. IHQ: inmunohistoquímica; FISH: hibridación in situ fluorescente. RT-qPCR: PCR cuantitativa en tiempo real. Basada en (2,17,18).

Factor	Descripción	Valor pronóstico
Factores clínico-patológicos clásicos		
Tamaño tumoral	Diámetro del tumor primario	Mayor tamaño (2-5 cm) asociado a mayor riesgo de metástasis
Afectación ganglionar	Infiltración tumoral en los ganglios linfáticos axilares	Presencia tumoral en los ganglios linfáticos mayor riesgo de recurrencia
Grado histológico	Diferenciación tumoral (escala I-III)	Mayor grado asociado a peor pronóstico y mayor riesgo de recurrencia
Estado ER/PR	Expresión de ER y PR por IHQ	ER+/PR+: mejor pronóstico, el tumor responderá a terapia endocrina PR-: mayor probabilidad de recurrencia
Estado HER2	Sobreexpresión o amplificación de <i>ERBB2</i> por IHQ/FISH	HER2+: mayor agresividad; uso terapia anti-HER2
Ki-67	Índice de proliferación celular	Ki-67 < 10% baja proliferación Ki-67 > 30% alta proliferación
Firmas génicas		
PAM50 (Prosigna®)	Expresión de 50 genes (Tecnología <i>nCounter</i>)	Asigna subtipo intrínseco y puntuación ROR
OncotypeDx®	Expresión de 21 genes (RT-qPCR)	Predice respuesta terapéutica en tumores ER+/HER2-
MammaPrint®	Expresión de 70 genes (<i>microarray</i>)	Clasifica riesgo de recurrencia a distancia en tumores ER+

Los recursos tecnológicos actuales permiten recolectar grandes volúmenes de datos de cada paciente, abarcando desde variables clínico-patológicas hasta perfiles genómicos y transcriptómicos. En este contexto, el aprendizaje automático emerge como una

herramienta especialmente adecuada para explotar toda esa información, identificar patrones complejos y elaborar modelos predictivos más precisos e individualizados, acercándonos más hacia la medicina de precisión.

2.5. Ciencias ómicas en cáncer de mama

La secuenciación de próxima generación (NGS, del inglés *Next-Generation Sequencing*), también denominada secuenciación de alto rendimiento, supuso un importante avance respecto a la secuenciación tradicional de Sanger al permitir la secuenciación masiva y paralela de millones de fragmentos de ADN y ARN. Su incorporación a la investigación biomédica revolucionó el estudio del genoma y del transcriptoma, haciendo posible la caracterización de alteraciones genéticas y de los perfiles de expresión génica con una profundidad, velocidad y coste sin precedentes.

En oncología, las tecnologías NGS se han consolidado como una herramienta esencial tanto para la investigación como para la práctica clínica. A diferencia de los métodos convencionales, que analizan un número limitado de genes, la secuenciación permite caracterizar miles de alteraciones moleculares a partir de una única muestra (20). Ello ha contribuido a comprender los mecanismos moleculares implicados en la carcinogénesis, a la identificación de nuevos biomarcadores o vías de señalización desreguladas en el tumor y a la categorización de los subtipos de cáncer, entre otros. Además, dado que un mismo tumor puede albergar poblaciones celulares con perfiles mutacionales distintos -lo que se conoce como heterogeneidad intratumoral- la NGS permite capturar esta complejidad molecular de forma global. Toda esta información constituye la base de la oncología de precisión, enfocada en el tratamiento personalizado del cáncer, la evaluación pronóstica y el seguimiento de la respuesta al tratamiento (21).

Las tecnologías NGS han impulsado el estudio de las distintas capas “ómicas” del cáncer de mama, entre las que destacan la genómica, la transcriptómica y la epigenómica. En este apartado se abordarán las dos primeras, pues son las dos fuentes de información molecular utilizadas en este trabajo.

2.5.1. Genómica

En el estudio del genoma del cáncer, el principal objetivo es la detección de mutaciones somáticas presentes en las células tumorales. Las tecnologías NGS pueden identificar variantes de un nucleótido, inserciones y deleciones (*indels*) y cambios estructurales comparando el genoma del tumor con el de células normales (21).

La secuenciación a gran escala permite analizar estas alteraciones mediante diferentes estrategias. En el ámbito de la investigación, la secuenciación del genoma completo (*Whole-Genome Sequencing*, WGS) proporciona una caracterización de la totalidad del ADN tumoral, mientras que la secuenciación del exoma completo (*Whole-Exome Sequencing*, WES) se centra exclusivamente en las regiones codificantes del genoma (exones), que representan aproximadamente el 1 % del ADN humano, pero contienen la mayoría de las variantes descritas causantes de enfermedades (20,22). Debido a su menor coste y mayor profundidad, el WES constituye una de las aproximaciones más empleadas en investigación oncológica.

2.5.2. Transcriptómica

Conocer el conjunto de moléculas de ARN transcritas en el cáncer permite obtener información no sólo sobre la expresión de los genes, sino también sobre los procesos de empalme alternativo (*alternative splicing*) o la expresión de ARN no codificantes como los microARNs, entre otros (21,22). A diferencia del genoma, el transcriptoma es altamente dinámico y refleja el estado funcional de la célula en un momento determinado, constituyendo el puente entre las alteraciones genéticas presentes en el ADN y el fenotipo tumoral (23).

La técnica de referencia para el estudio del transcriptoma es la secuenciación de ARN (*RNA sequencing* o RNA-Seq), que permite cuantificar la expresión de miles de genes mediante la secuenciación del ADN complementario (ADNc) obtenido a partir del ARN de la muestra. Los datos generados se analizan mediante diferentes aproximaciones, entre las que destaca el análisis de expresión diferencial, ampliamente utilizado para identificar aquellos genes

con patrones de expresión génica significativamente diferentes entre distintas condiciones biológicas o grupos de muestras (23).

2.5.3. Proyectos colaborativos para la caracterización molecular del cáncer

El desarrollo y consolidación de las tecnologías de secuenciación y otras tecnologías de alto rendimiento ha permitido generar grandes volúmenes de información biológica a distintos niveles, incluyendo datos genómicos, transcriptómicos, proteómicos y metabolómicos, entre otros. Dado que el cáncer de mama -y el cáncer en general- es una enfermedad altamente compleja, su estudio integral, considerando de forma conjunta las alteraciones en el genoma, la desregulación de la expresión génica y los cambios en la funcionalidad proteica, resulta fundamental para avanzar en su comprensión (24). En este contexto nacieron grandes proyectos internacionales como el de *The Cancer Genome Atlas* (TCGA), dedicados a caracterizar molecularmente los distintos tipos de cáncer a una escala multi-ómica.

El proyecto TCGA fue impulsado en 2006 por el *National Cancer Institute* (NCI) y el *National Human Genome Research Institute* (NHGRI), con el principal objetivo de proporcionar conjuntos de datos de acceso público para mejorar los protocolos clínicos y, en definitiva, prevenir el cáncer (25). El proyecto recopila información molecular y clínica de más de 30 tipos de cáncer y 11.000 pacientes (26). En cáncer de mama, destaca el estudio desarrollado por *The Cancer Genome Atlas Network*, que fue pionero en integrar datos de seis plataformas ómicas distintas: matrices de número de copias (CNV), WES, metilación del ADN, matrices de ARN, secuenciación de microARN y matrices de proteínas en fase reversa (RPPA, por sus siglas en inglés). Este estudio permitió consolidar los cuatro subtipos moleculares principales de cáncer de mama (sin incluir el tipo Normal) e identificar nuevas alteraciones y vías de señalización implicadas en la enfermedad (véase apartados 2.2 y 2.3) (13).

Los datos generados por el proyecto TCGA se encuentran disponibles de forma pública en la plataforma *Genomic Data Commons* (GDC), desarrollada por el NCI, que centraliza el

almacenamiento, la normalización y el acceso a los datos procedentes de múltiples programas de investigación oncológica a gran escala (27).

2.6. Aprendizaje automático y sus aplicaciones en oncología

La digitalización de la medicina y el auge de las tecnologías ómicas han dado lugar a una era de *big data* biomédico que requiere de técnicas más avanzadas que los métodos estadísticos convencionales para su análisis. En este sentido, la inteligencia artificial (IA) se ha consolidado en los últimos años como una herramienta esencial para la investigación oncológica (28).




Figura 5. Aplicaciones de la inteligencia artificial en oncología de precisión. Se muestran diez “hallmarks” organizados en 3 grupos: prevención, optimización de los tratamientos actuales y descubrimiento de nuevos tratamientos. Obtenida de (28).

El concepto de inteligencia artificial surgió en la década de 1950 con el propósito de desarrollar sistemas capaces de realizar tareas que requieren inteligencia humana, como el razonamiento, el aprendizaje o la toma de decisiones. La IA se basa en algoritmos y modelos matemáticos capaces de analizar grandes volúmenes de datos e identificar patrones y relaciones complejas entre ellos (29). Sus aplicaciones en oncología abarcan prácticamente todas las etapas del manejo del paciente: desde el análisis de imágenes médicas para la detección del tumor hasta el descubrimiento de biomarcadores de respuesta a tratamiento y el desarrollo de nuevas estrategias terapéuticas (Figura 5) (28).

Dentro del campo de la inteligencia artificial, el aprendizaje automático (AA) constituye una de sus principales ramas y comprende un grupo de algoritmos capaces de aprender y mejorar su rendimiento de forma automática a partir de los datos, sin necesidad de ser programados explícitamente para cada tarea (29,30). A diferencia de los programas convencionales, que ejecutan instrucciones predefinidas, los modelos de AA se entrenan sobre conjuntos de datos para generalizar patrones y, posteriormente, realizar predicciones o clasificaciones sobre nuevas observaciones.

Los algoritmos de aprendizaje automático se pueden clasificar en aprendizaje supervisado, no supervisado y por refuerzo. En el aprendizaje supervisado, el modelo se entrena a partir de datos etiquetados y éste aprende a predecir la clase de los datos, mientras que el aprendizaje no supervisado trabaja con datos sin etiquetar, buscando estructuras o agrupaciones ocultas en los datos (30). En oncología, los métodos supervisados suelen emplearse cuando existe una variable clínica de interés, como la respuesta a tratamiento o el subtipo molecular, mientras que los no supervisados resultan muy útiles para análisis exploratorios, detectar patrones de expresión o identificar subgrupos de pacientes (24). El aprendizaje por refuerzo, no muy común en este ámbito, busca qué acciones tomar basado en un sistema de recompensa (30).

La elección del modelo de inteligencia artificial o del algoritmo de aprendizaje automático depende en gran medida de la naturaleza de los datos y el objetivo de la investigación. Los

algoritmos clásicos de AA son muy efectivos para el análisis de datos tabulares, como los datos clínicos y perfiles genómicos o transcriptómicos, siendo ampliamente utilizados para el desarrollo de modelos pronósticos. Por otro lado, el aprendizaje profundo (*deep learning*) constituye un subcampo del aprendizaje automático basado en redes neuronales artificiales con múltiples capas, capaces de aprender representaciones complejas de los datos. Estos modelos han demostrado un gran rendimiento en análisis de datos no estructurados, como las imágenes radiológicas, donde son capaces de detectar patrones espaciales más complejos (28,31).

2.6.1. Aprendizaje automático para la predicción pronóstica en cáncer de mama

Como se ha comentado anteriormente, tradicionalmente el estado del tumor o la afectación ganglionar han sido los métodos clásicos para estratificar el riesgo de recurrencia metastásica en cáncer de mama. Sin embargo, los modelos de inteligencia artificial han demostrado ser más precisos gracias a la combinación simultánea de múltiples variables clínicas y moleculares (28,32). Cuanto más precisa sea la estimación del pronóstico, más adecuada podrá ser la elección del tratamiento, permitiendo además un seguimiento más individualizado y una identificación precoz de las pacientes con mayor riesgo de recaída.

Los datos moleculares, tales como los perfiles genómicos o transcriptómicos, ofrecen una visión más profunda de la biología del tumor que no puede capturarse únicamente con las variables clínico-patológicas convencionales. Por ello, comenzaron a incorporarse junto a las variables clínicas para desarrollar modelos pronósticos más precisos. En esta línea, Fan *et al.* (2011) fueron de los primeros en integrar variables clínico-patológicas y firmas de expresión génica en un único modelo pronóstico de aprendizaje automático para cáncer de mama, mostrando que esta combinación mejoraba la predicción del riesgo de recaída frente al uso aislado de cada tipo de variable (32).

En los últimos años, la creciente disponibilidad de datos procedentes de múltiples plataformas ómicas ha impulsado el desarrollo de modelos pronósticos integrativos con el fin de captar de forma más completa la heterogeneidad tumoral y mejorar la estratificación

pronóstica (33–36). Los métodos de aprendizaje automático permiten abordar problemas derivados de la combinación de estos datos, como la alta dimensionalidad, el ruido o el tamaño muestral limitado (35,36).

La hipótesis común de estos enfoques es que cada modalidad de datos aporta información complementaria sobre la biología del tumor y su evolución clínica, de modo que su integración produce modelos más robustos que los construidos a partir de una única fuente de datos. Esto se ha demostrado en numerosos trabajos, tanto en estudios de integración transcriptómica, donde la combinación de ARNm, ARNlnc y miARN mejoró la clasificación pronóstica frente al análisis por separado de cada clase (37), como en modelos multimodales más amplios, que integraron información clínica, inmunohistoquímica, transcriptómica, genómica, metabolómica y de CNV, obteniendo un mayor rendimiento en la estratificación del riesgo a recurrencia en cáncer de mama (38).

3. Hipótesis y objetivos

La hipótesis de partida de este trabajo es que la integración de información genómica y transcriptómica permite representar de forma más completa la heterogeneidad molecular del cáncer de mama y, en consecuencia, desarrollar modelos de aprendizaje automático capaces de predecir la supervivencia con mayor precisión que utilizando un único tipo de dato molecular.

El objetivo principal de este estudio es desarrollar modelos de aprendizaje automático basados en datos de expresión génica y de mutaciones somáticas para la predicción de supervivencia en pacientes con cáncer de mama. Para ello, se persiguen los siguientes objetivos específicos:

- Obtener, integrar y preprocesar los datos clínicos, genómicos y transcriptómicos de pacientes con cáncer de mama procedentes del proyecto TCGA.
- Construir una variable respuesta a partir de los datos clínicos para estratificar los pacientes en función de su pronóstico.
- Entrenar algoritmos de aprendizaje automático utilizando de forma independiente datos de mutaciones somáticas y de expresión génica.
- Entrenar algoritmos de aprendizaje automático basados en la integración de las dos capas ómicas.
- Evaluar y comparar la capacidad predictiva de los distintos modelos e identificar aquel con mayor rendimiento.

En la figura 6 se muestra un diagrama de flujo que resume los pasos que se han seguido en este trabajo.




Figura 6. Diagrama de flujo general del Trabajo Fin de Máster.

4. Material y métodos

4.1. Entorno computacional

Todos los análisis bioinformáticos y estadísticos descritos en el presente trabajo se realizaron en el lenguaje de programación R (versión 4.4.2), empleando el entorno de desarrollo integrado RStudio (versión 2024.12). Los principales paquetes empleados en cada etapa del análisis se detallan a lo largo de los subapartados correspondientes. Los *scripts* desarrollados para el procesamiento y análisis de los datos se encuentran disponibles de forma pública en el siguiente repositorio de [GitHub](#).

4.2. Obtención de datos y preprocesamiento inicial

Este estudio incluyó una cohorte inicial de 1098 pacientes con cáncer de mama invasivo pertenecientes al proyecto *The Cancer Genome Atlas*, cuyos datos se encuentran disponibles en el portal de *Genomic Data Commons*. Se descargaron los datos clínicos, de expresión génica y de mutaciones somáticas mediante el paquete TCGAbiolinks (versión 2.34.1) del proyecto Bioconductor.

Para los datos de expresión génica, se descargaron los archivos de cuantificación procedentes del flujo de trabajo *STAR-Counts*. Este *pipeline* proporciona la matriz de recuentos por gen tras el alineamiento de las lecturas de RNA-Seq mediante el software STAR (39). Se seleccionaron exclusivamente las muestras correspondientes a tumor primario, con el fin de garantizar la homogeneidad molecular de los datos, excluyendo aquellas provenientes de tejido normal y metastásico.

Para los datos de mutaciones somáticas, se obtuvo el archivo MAF (*Mutation Annotation Format*), que contiene información detallada sobre las variantes somáticas identificadas en las muestras. Los datos procedían de secuenciación de exoma completo. Al igual que en el caso anterior, se filtraron exclusivamente las muestras de tumor primario.

Debido a que un mismo paciente puede disponer de más de una muestra biológica o técnica dentro del proyecto TCGA, el número de muestras disponibles no coincidió con el número de pacientes únicos. Por este motivo, los identificadores de las muestras se homogeneizaron a nivel de paciente, conservándose sólo una muestra por individuo. Tras este proceso, se identificaron los pacientes con información disponible para las 3 modalidades de datos, que fueron los que finalmente se incluyeron en el estudio, obteniendo una cohorte final de 965 pacientes (Tabla 2).

Tabla 2. Tamaño de los conjuntos de datos empleados en el estudio. La columna común hace referencia al número de pacientes con datos completos en los 3 conjuntos de datos.

	<i>Expresión génica</i>	<i>Mutaciones somáticas</i>	<i>Datos clínicos</i>	<i>Común</i>
<i>Muestras</i> (<i>incluye duplicados biológicos y/o técnicos</i>)	1111	991	-	-
<i>Pacientes únicos (n)</i>	1095	968	1098	965

4.3. Exploración de datos clínicos y definición de la variable respuesta

Se realizó un análisis exploratorio sobre las variables clínicas con el objetivo de caracterizar la cohorte y establecer la variable de respuesta empleada posteriormente en los modelos de aprendizaje automático. En la caracterización se incluyeron variables como el subtipo molecular, la edad al diagnóstico y el estadio del tumor, que corresponde a la extensión de la enfermedad. Entre las variables relacionadas con la supervivencia, se consideraron el estado vital (*vital status*), los días hasta fallecimiento (*days to death*) -en el caso de pacientes fallecidos- y los días hasta último seguimiento (*days to last follow-up*).

Para clasificar los pacientes según su supervivencia, se evaluaron inicialmente distintos puntos de corte (supervivencia a 3, 4 y 5 años) para comparar el número de pacientes que podían ser incluidos en la clasificación (Tabla 3). Finalmente, se estableció el horizonte temporal de 3 años, al proporcionar un mayor tamaño muestral para el desarrollo de los

modelos predictivos. De esta forma, los pacientes que habían fallecido antes de dicho periodo fueron clasificados como “Alto riesgo” (*High risk*), mientras que aquellos que habían sobrevivido al menos 3 años fueron clasificados como “Bajo riesgo” (*Low risk*). Los pacientes cuyo último seguimiento disponible era inferior a 3 años fueron excluidos del análisis. Es importante señalar que las categorías “Alto/Bajo riesgo” son abreviaturas para categorizar el desenlace observado (supervivencia a 3 años), y pertenecer a la categoría “Bajo riesgo” no implica necesariamente un buen pronóstico a largo plazo.

Tabla 3. Número de pacientes clasificables según el horizonte temporal de supervivencia.

<i>Supervivencia</i>	<i>Sí (Bajo riesgo)</i>	<i>No (Alto riesgo)</i>	<i>Clasificables (n)</i>	<i>Excluidos</i>
<i>3 años</i>	380	64	444	521
<i>4 años</i>	286	76	362	603
<i>5 años</i>	218	88	306	659

4.4. Preprocesamiento y análisis exploratorio

4.4.1. Datos de expresión génica

Los datos de expresión génica se sometieron a un filtrado de recuentos bajos de lecturas para eliminar genes con expresión insuficiente y reducir el tamaño de la matriz. Se retuvieron aquellos genes que presentaban un mínimo de 10 lecturas en al menos 10 muestras. Posteriormente, los datos se normalizaron mediante la transformación estabilizadora de varianza (VST, del inglés *Variance Stabilizing Transformation*), implementada en el paquete DESeq2 (versión 1.46.0). Esta transformación tiene como objetivo eliminar la dependencia de la varianza respecto a la media, generando datos de expresión aproximadamente homocedásticos y adecuados para los análisis exploratorios posteriores y representaciones gráficas. La transformación se realizó estableciendo el

parámetro “*blind= TRUE*”, de modo que no estuviese condicionada por el diseño experimental (40).

El análisis exploratorio se realizó únicamente sobre los 444 pacientes incluidos en la clasificación de riesgo. Se seleccionaron los 1 000 genes con mayor varianza entre las muestras, sobre los que se realizó un análisis de componentes principales (PCA), y un mapa de calor con agrupamiento jerárquico mediante el método de Ward.D2. Para ello, se empleó el paquete stats (versión 4.4.2), incluido en RBase, y el paquete pheatmap (versión 1.0.13), respectivamente.

4.4.2. Datos de mutaciones somáticas

Los datos de mutaciones somáticas fueron explorados inicialmente mediante el paquete maftools (versión 2.22.0), que permite el análisis y la visualización de variantes somáticas directamente a partir de archivos MAF (41). A través de los resúmenes y representaciones gráficas proporcionadas por el paquete, se examinó la distribución de las variantes en la cohorte, las clases de mutaciones identificadas y la frecuencia de mutación por gen.

Para su posterior utilización en los modelos de aprendizaje automático, los datos se transformaron en una matriz binaria con estructura paciente x gen. Previamente, se aplicaron dos criterios de filtrado: se excluyeron las variantes silenciosas, al no tener impacto a nivel proteico, y aquellas consideradas como benignas según el predictor de impacto funcional Polyphen (puntuación $\leq 0,446$). La presencia de al menos una mutación en un gen dado se codificó como 1, y su ausencia como 0.

4.5. Selección de variables y construcción de los modelos predictivos

Tras el preprocesamiento inicial, la cohorte de 444 pacientes se dividió aleatoriamente en un conjunto de entrenamiento y prueba mediante partición estratificada empleando el paquete caret (versión 7.0.1), manteniendo la proporción de pacientes pertenecientes a cada grupo de riesgo. El 80% de la cohorte se destinó al conjunto de entrenamiento y el 20% restante al conjunto de prueba. Previo al entrenamiento de los modelos, se llevó a

cabo una etapa de selección de variables específica para cada tipo de dato ómico, realizada únicamente sobre el conjunto de entrenamiento para evitar filtración de información durante el desarrollo de los modelos. En la figura 7 se representa esquemáticamente los análisis realizados sobre los datos de cada capa ómica según el objetivo.




Figura 7. Diagrama de flujo de los análisis exploratorios y selección de variables para cada modalidad ómica. Se muestran los datos de partida y los pasos seguidos según los objetivos del análisis. EDA: Exploratory Data Analysis.

4.5.1. Selección de genes diferencialmente expresados

Para los datos transcriptómicos, la selección de variables se realizó mediante análisis de expresión diferencial entre los grupos de alto y bajo riesgo, empleando el paquete DESeq2. Para ello, se partió nuevamente de los conteos de lecturas sin transformar. Sobre esta matriz se aplicó el mismo criterio de filtrado por baja expresión descrito en el preprocesamiento. Se consideraron diferencialmente expresados aquellos genes con un valor de p ajustado (*False Discovery Rate*, FDR) inferior a 0,01 y un cambio en la expresión en valor absoluto ($|\log_2 \text{fold change}|$) superior a 1. Se estableció el grupo Bajo riesgo como categoría de referencia. Los genes resultantes fueron empleados como variables de entrada en los modelos de aprendizaje automático.

Adicionalmente, se llevó a cabo un análisis de enriquecimiento de conjuntos de genes (GSEA, *Gene Set Enrichment Analysis*) para identificar procesos biológicos sobrerrepresentados en el perfil de expresión génica. Para ello, los genes se ordenaron según el estadístico de Wald obtenido tras el análisis de expresión diferencial, que representa el valor de la magnitud de cambio ($\log_2 \text{fold change}$) entre su error estándar. Los conjuntos de genes fueron obtenidos de la colección *Hallmark* de la base de datos *Molecular Signature Database* (MsigDB) mediante el paquete msigdb (versión 26.1). El análisis de enriquecimiento se realizó mediante el paquete fgsea (versión 1.32.4), considerando conjuntos génicos de entre 15 y 500 genes. Se consideraron estadísticamente significativos los conjuntos enriquecidos con $\text{FDR} < 0,05$. Un valor NES (*Normalized Enrichment Score*) positivo indicó procesos sobrerrepresentados en el grupo Alto riesgo, mientras que un NES negativo indicó procesos reprimidos o asociados a Bajo riesgo.

4.5.2. Selección de variables mutacionales

Para los datos de mutaciones somáticas, se aplicó en primer lugar un filtrado por frecuencia, reteniéndose únicamente aquellos genes que presentaban mutaciones en al menos 4 muestras, correspondiente aproximadamente al 1% de la cohorte de entrenamiento.

Posteriormente, se aplicó un modelo de regresión logística penalizada mediante LASSO (del inglés *Least Absolute Shrinkage and Selection Operator*), implementado mediante el paquete *glmnet* (versión 4.1.10). Se fijó una semilla de aleatoriedad previa al modelo para garantizar la reproducibilidad de los resultados. El parámetro de regularización λ se seleccionó mediante validación cruzada de 10 pliegues, utilizando el valor que minimizó el error de clasificación (*lambda.min*). Las variables cuyos coeficientes fueron distintos de cero se consideraron candidatas para los modelos predictivos.

4.5.2.1. Agrupación por vías de señalización

Debido a la elevada dispersión de la matriz a nivel de gen, seguidamente se optó por agregar la información mutacional a nivel de vías de señalización, con el objetivo de reducir la dimensionalidad y agrupar alteraciones potencialmente relacionadas funcionalmente.

Para ello, los genes se mapearon a las rutas definidas por la base de datos KEGG (*Kyoto Encyclopedia of Genes and Genomes*), obtenidas a través del paquete *msigdb*. De la misma forma que para las mutaciones, se construyó una matriz binaria a nivel de vía, en la que cada paciente era portador de una alteración cuando al menos uno de los genes pertenecientes a dicha vía presentaba una mutación. De la misma forma que en el apartado anterior, se seleccionaron las vías con mayor capacidad discriminativa mediante LASSO.

4.5.3. Integración ómica

Por último, para evaluar la hipótesis de este trabajo, las variables seleccionadas para cada modalidad ómica se concatenaron en una única matriz, siguiendo una estrategia de integración temprana (*early fusion*) (35). De esta forma, la matriz multi-ómica estaba constituida por los genes diferencialmente expresados identificados mediante DESeq2 y las vías de señalización seleccionadas mediante LASSO a partir de los datos de mutaciones somáticas.

Finalmente, la matriz resultante se utilizó como conjunto de variables predictoras para el entrenamiento de los modelos de aprendizaje automático, siguiendo el mismo procedimiento de evaluación empleado para los modelos individuales.

4.6. Entrenamiento y evaluación de los modelos predictivos

Se entrenaron tres modelos de aprendizaje automático para clasificar a los pacientes según su supervivencia a 3 años: máquinas de vectores de soporte con kernel lineal (*Support Vector Machines*, SVM lineal), máquinas de vectores de soporte con kernel radial (SVM radial) y *Random Forest* (RF). Los algoritmos se implementaron mediante la función *train* del paquete *caret*. Primero, estos modelos se entrenaron de manera individual para cada modalidad ómica utilizando las variables seleccionadas. Para poder comparar entre modalidades, luego se entrenaron sobre la matriz integrada. Previo al entrenamiento de todos los modelos se fijó una semilla de aleatoriedad.

Para garantizar la robustez de los modelos, el entrenamiento se realizó mediante validación cruzada estratificada repetida de 10 pliegues y 5 repeticiones. En cada repetición, los datos de entrenamiento se dividieron en 10 subconjuntos, utilizando alternativamente cada uno de ellos como validación y el restante para el ajuste del modelo. Para cada combinación de hiperparámetros se calcularon el área bajo la curva ROC (*Area Under the Curve*, AUC), la sensibilidad y la especificidad. El AUC se utilizó como métrica para seleccionar los hiperparámetros óptimos para cada modelo.

Los modelos SVM se entrenaron aplicando centrado y escalado de las variables predictoras de expresión génica mediante una transformación *Z-score*. Las variables mutacionales, al estar codificadas como una matriz binaria, no se estandarizaron.

Durante el entrenamiento de SVM lineal se evaluaron cuatro valores del hiperparámetro de regularización C : 0,01, 0,1, 1 y 10. En cuanto al SVM radial, los hiperparámetros son C y σ se evaluaron automáticamente por el modelo de entre una secuencia de 4 valores.

Para el modelo *Random Forest*, se evaluaron diferentes valores del hiperparámetro $mtry$, correspondiente al número de variables predictoras consideradas aleatoriamente como candidatas en cada división de los árboles. Para la modalidad de expresión se evaluaron 3 valores manualmente: 5, 25 y 50. Para las variables mutacionales y el modelo integrado, el hiperparámetro óptimo se escogió automáticamente por el modelo de entre una secuencia

de 3 valores. En este modelo no se realizó centrado ni escalado de las variables, ya que RF no requiere que las variables predictoras se encuentren en una escala común.

Una vez seleccionada la combinación óptima de hiperparámetros mediante la validación cruzada, los modelos ajustados y entrenados sobre los datos de entrenamiento se utilizaron para realizar las predicciones sobre el conjunto de prueba, correspondiente al 20% de la cohorte.

El rendimiento predictivo de los modelos se evaluó mediante la curva ROC (*Receiver Operating Characteristic*) y el AUC con su intervalo de confianza (IC) al 95%. Para ello, se utilizó el paquete pROC (versión 1.19.0.1). Asimismo, se calcularon las siguientes métricas de rendimiento a partir de la matriz de confusión obtenida al comparar las predicciones del modelo con las etiquetas reales del conjunto de prueba:

- $Exactitud = \frac{TP+TN}{TP+FP+TN+FN}$
- $Sensibilidad = \frac{TP}{TP+FN}$
- $Especificidad = \frac{TN}{TN+FP}$
- $Precisión = \frac{TP}{TP+FP}$
- $Puntuación F1 = \frac{2TP}{(2TP+FP+FN)}$

Para la clasificación binaria se consideró como clase positiva el grupo de alto riesgo (*High risk*). De esta forma, verdaderos positivos (TP, *True Positive*) fueron aquellos pacientes de alto riesgo clasificados correctamente, y falsos positivos (FP, *False Positive*) aquellos pacientes de bajo riesgo clasificados como alto riesgo. Por otro lado, verdadero negativo (TN, *True Negative*) fueron aquellos pacientes de bajo riesgo clasificados correctamente, y falso negativo (FN, *False Negative*), los pacientes de alto riesgo clasificados por el modelo como bajo riesgo.

5. Resultados

5.1. Descripción de la cohorte

Tras la eliminación de duplicados técnicos y tras la integración de la información clínica, transcriptómica y mutacional, se obtuvo una cohorte final de 965 pacientes con cáncer de mama. La edad media al diagnóstico fue de 58 años, coincidiendo prácticamente con la mediana (58,26 años) (figura 8A). El 50% de los pacientes presentaban una edad comprendida entre los 49 y 67 años cuando fueron diagnosticados con la enfermedad.




Figura 8. Caracterización clínica y molecular de la cohorte TCGA-BRCA (n=965).

La distribución de los subtipos moleculares definidos por la firma PAM50, representada en la figura 8B, mostró un predominio de los tumores de tipo luminal A, con 486 pacientes, seguido de los subtipos luminal B (192 pacientes) y basal (167 pacientes). Sobre la distribución del estadio tumoral (figura 8C), el estadio II fue el más frecuente, seguido del

III y I. El estadio IV, que hace referencia a la diseminación del tumor a otros tejidos (metástasis), fue el menos representado.

En cuanto al estado vital, 832 pacientes de nuestra cohorte se encontraban vivos y 133 habían fallecido en el momento del último seguimiento disponible. Para los pacientes vivos, el tiempo medio de seguimiento fue de 747 días (aproximadamente 2 años), cuya distribución se muestra en la figura 9. Dado que 521 pacientes no disponían de seguimiento más allá de los 3 años (correspondiente a aproximadamente el 50% de la cohorte), estos quedaron excluidos para los análisis posteriores, puesto que no podía determinarse su estado a dicho punto (tabla 3).




Figura 9. Distribución del tiempo de seguimiento en los pacientes vivos. La línea amarilla muestra el horizonte temporal de 3 años para la definición de la variable de supervivencia.

En el caso de los pacientes fallecidos (figura 10), el tiempo medio hasta el fallecimiento fue de 1.142 días (3,1 años). 64 pacientes fallecieron antes de 3 años, que fueron clasificados como Alto riesgo, mientras que los 69 restantes que lograron sobrevivir a este periodo se incluyeron en la categoría Bajo riesgo.




Figura 10. Distribución del tiempo hasta el fallecimiento en pacientes fallecidos.

5.1.1. Cohorte incluida en la clasificación de riesgo

Con todo lo anterior, se obtuvo una cohorte final de 444 pacientes para desarrollar este trabajo. De estos, 380 (85,5%) fueron clasificados como Bajo riesgo y 64 (14,4%) como Alto riesgo según su supervivencia a 3 años, resultando en un notable desbalance entre clases con una proporción aproximada de 6:1. La edad media al diagnóstico para el grupo de alto riesgo fue de 63,9 años, mientras que para el grupo de bajo riesgo fue de 55,7 años, ambos con una distribución amplia de edad (figura 11).




Figura 11. Distribución de la edad al diagnóstico según el grupo de riesgo (n=444).

La distribución de los subtipos moleculares mostró algunas diferencias visibles entre los grupos de riesgo (figura 12A). El grupo Bajo riesgo estuvo constituido mayoritariamente por tumores de tipo Luminal A, representando el 52% de los tumores de este grupo, seguido del subtipo Luminal B, Basal, enriquecido en HER2 y Normal. A su vez, dentro de cada subtipo, cabe destacar el marcado patrón del subtipo Luminal A, donde únicamente el 10% este subtipo pertenecía a la categoría Alto riesgo.

La distribución del estadio tumoral mostró también diferencias entre los grupos de riesgo (figura 12B). En el grupo de Bajo riesgo predominaron los tumores en estadios iniciales, mientras que en el grupo de Alto riesgo se observó una mayor representación relativa de estadios más avanzados.





Figura 12. Distribución del subtipo molecular (A) y estadio (B) según el grupo de riesgo.

Las diferencias observadas en edad, estadio y subtipo molecular se presentan con carácter descriptivo. Estas variables no se incluyeron como predictores en los modelos, por lo que no puede determinarse si explican de forma independiente parte de las diferencias observadas entre los grupos.

5.2. Exploración de la expresión génica

Inicialmente, la matriz de recuentos de lecturas contenía 60 660 variables, de las cuales, tras el filtro por baja expresión, se retuvieron 34 440, correspondientes a diversos tipos de genes, incluyendo genes codificantes de proteínas, pseudogenes, ARNInc, etc. Con el fin de explorar la estructura de los datos transcriptómicos, se llevó a cabo un análisis de componentes principales sobre los 1 000 genes con mayor variabilidad, utilizando la matriz de expresión normalizada. Los dos primeros componentes principales (PC1 y PC2) explicaron un 19% y un 9% de la varianza total, respectivamente.

Figura 13. Análisis de componentes principales de los perfiles de expresión génica. (A) Representación de las dos primeras componentes principales, coloreada según el subtipo molecular PAM50. (B) Misma representación coloreada según el grupo de riesgo definido por la supervivencia a 3 años.



La representación gráfica de los pacientes en el espacio definido por PC1 y PC2 se muestra en la figura 13. Al colorear las muestras según el subtipo molecular definido por PAM50, se observó una separación clara del subtipo Basal del resto de subtipos, mientras que los subtipos luminales y HER2-enriquecido presentaron un mayor grado de solapamiento

(figura 13A). Al representar las mismas componentes coloreadas según el grupo de riesgo, no se observó una separación clara entre los pacientes clasificados como Bajo riesgo y Alto riesgo (figura 13B).

La representación de los datos de expresión de los 1 000 genes más variables en un mapa de calor con el agrupamiento jerárquico reveló distintos patrones de expresión entre muestras y genes (figura 14). El agrupamiento de los pacientes mostró una distribución consistente con el subtipo molecular PAM50, donde de nuevo se identificó un clúster aislado del resto compuesto por muestras de tipo Basal, mientras que los subtipos Luminal A y Luminal B presentaron cierto grado de mezcla. Se pudo observar además un clúster formado mayoritariamente por el subtipo HER2-enriquecido, mientras que los tumores de tipo Normal se distribuyeron entre todos los grupos. En cuanto a los genes, se observaron 5 grandes grupos con patrones de expresión diferenciados.




Figura 14. Mapa de calor de la expresión génica para los 1 000 genes más variables. La expresión génica se representa tras la normalización VST y posterior estandarización mediante Z-score para cada transcrito.

5.3. Caracterización de las mutaciones somáticas

Se identificaron 36 542 variantes somáticas en las muestras de tumor primario de la cohorte de 444 pacientes, que comprendían 34 899 SNP (*Single Nucleotide Polymorphism*), 1 279 deleciones, 361 inserciones y 3 variantes de tipo ONP (*Oligo-Nucleotide Polymorphism*), correspondientes a una sustitución de más de 3 nucleótidos seguidos.

De las variantes de un único nucleótido, la clase más frecuente fueron las mutaciones de cambio de sentido (*missense*), con 23 179 variantes, en las que la sustitución nucleotídica conlleva el cambio de un aminoácido en la secuencia proteica. Asimismo, se identificaron mutaciones sin sentido (*nonsense*), alteraciones en sitios de *splicing* y mutaciones de desplazamiento del marco de lectura (*frame-shift*), entre otras (figura 15). Además, se identificaron 9 185 variantes silenciosas, que fueron excluidas de los análisis posteriores.




Figura 15. Gráfico resumen de las mutaciones somáticas identificadas en la cohorte (n=444). No se incluyen las mutaciones silenciosas.

Los 10 genes más frecuentemente mutados en la cohorte fueron *TP53*, *PIK3CA*, *TTN*, *MUC16*, *GATA3*, *CDH1*, *MAP3K1*, *KMT2C*, *RYR2* y *SPTA1*. No obstante, *TTN* y *MUC16* fueron identificados por *maftools* como posibles FLAGS, cuyas siglas hacen referencia a *Frequently Mutated Genes* y representan genes con frecuencias de mutación elevadas, generalmente asociadas a su gran longitud de secuencia, y no necesariamente a un papel conductor en la oncogénesis (42).



Figura 16. Paisaje mutacional de los 10 genes más frecuentemente mutados en la cohorte.

La mediana de mutaciones por muestra fue de 33, aunque se identificó un individuo con una carga mutacional absoluta excepcionalmente elevada de 3 783 variantes. La figura 16 muestra el *oncoplot* con el perfil mutacional de la cohorte para los 10 genes más frecuentemente mutados. Cada columna representa un paciente con un diagrama de barras en la parte superior indicando su carga mutacional absoluta, y cada fila corresponde a un gen. El tipo de mutación se representa mediante un código de colores, permitiendo observar tanto la frecuencia de alteración de cada gen como la consecuencia funcional de

las variantes. *TP53* y *PIK3CA* presentaron las mayores frecuencias de mutación (35% y 34%, respectivamente). De acuerdo con lo mencionado anteriormente, las mutaciones de cambio de sentido fueron la clase predominante en la mayoría de los genes, a excepción de *GATA3* y *CDH1*, donde la clase mayoritaria fueron mutaciones de desplazamiento del marco de lectura y mutaciones sin sentido, respectivamente. En negro se representan las muestras que presentan más de un tipo de variante en un mismo gen (*Multi_Hit*).

Tras la exploración, se construyó la matriz binaria de mutaciones, que, tras la eliminación de las variantes silenciosas y benignas, se obtuvieron 8 961 genes con al menos una mutación en la cohorte analizada.

5.4. Selección de variables

La partición estratificada dividió la cohorte en 356 pacientes (80%) destinados al conjunto de entrenamiento y 88 (20%) destinados al conjunto prueba, manteniendo en ambos la proporción original de pacientes por grupo de riesgo (304/52 para el conjunto de entrenamiento y 76/12 para el de prueba).

En síntesis, los datos de expresión génica contenían 34 440 variables y los de mutaciones somáticas 8 961 tras el filtrado y preprocesamiento inicial. Debido a la alta dimensionalidad de ambas matrices, se optó por realizar una selección de variables previa al desarrollo de los modelos predictivos, únicamente sobre el conjunto de entrenamiento.

5.4.1. Genes diferencialmente expresados entre grupos de riesgo

Se identificaron 499 genes diferencialmente expresados entre los dos grupos de supervivencia en el conjunto de entrenamiento con $FDR < 0,01$ y $|\log_2 \text{fold change}| > 1$ (figura 17). De ellos, 108 se encontraban sobreexpresados y 391 subexpresados en Alto riesgo respecto a Bajo riesgo, lo que supuso un predominio de genes con expresión reducida en los pacientes con supervivencia inferior a 3 años, representando el 78% del total de genes diferencialmente expresados.

La expresión de los 50 genes diferencialmente expresados con mayor significación estadística se representó en un mapa de calor (figura 18). El agrupamiento jerárquico de las muestras no mostró una separación clara entre los grupos de riesgo. No obstante, cabe destacar el agrupamiento de genes relacionados con las inmunoglobulinas, que mostraron patrones de expresión similares entre las muestras.

El análisis de enriquecimiento mediante GSEA identificó 29 conjuntos génicos de la colección *Hallmark* con un enriquecimiento estadísticamente significativo ($FDR < 0,05$). En la figura 19 se representan los 15 procesos enriquecidos con mayor magnitud de NES. Entre los conjuntos y vías con enriquecimiento positivo, sobrerrepresentados en Alto riesgo, destacaron las dianas de E2F (NES=3), las dianas de MYC (NES=2,82), la glucólisis (NES=2,65) y la señalización de mTORC1 (NES=2,65). También cabe destacar el enriquecimiento positivo en las vías de punto de control G2/M del ciclo celular, reparación del ADN e hipoxia. En cuanto a los conjuntos génicos con un enriquecimiento negativo, destacaron los asociados con rechazo de aloinjerto (NES=-2,31), respuesta temprana a estrógenos (NES=-1,95) y respuesta al interferón gamma (-1,91).




Figura 19. Gráfico de enriquecimiento GSEA para los 15 procesos Hallmark más significativos.

5.4.2. Variables mutacionales seleccionadas

De 8 961 genes presentes en la matriz binaria de mutaciones, se retuvieron 404 genes mutados en al menos 4 muestras del conjunto de entrenamiento. Sin embargo, el modelo LASSO aplicado sobre la matriz no seleccionó ningún gen, puesto que todos los coeficientes fueron reducidos a cero.

Debido a la alta dispersión de la matriz a nivel de gen individual y la dificultad para discriminar entre grupos de riesgo, se optó por agrupar los genes a nivel de vías de señalización definidas por la base de datos KEGG. De los 8 961 genes presentes en la matriz binaria original, 2 552 se encontraban anotados en alguna de las 186 vías KEGG disponibles. Para cada paciente, cada vía se codificó nuevamente de forma binaria según la presencia o ausencia de al menos una mutación en los genes que la componen, generando una nueva matriz de dimensiones 444 pacientes $\times$ 186 vías.

Tabla 4. Vías metabólicas y de señalización KEGG seleccionadas mediante regresión LASSO en el conjunto de entrenamiento. Se muestran las vías con coeficientes distintos de cero en el modelo correspondiente a $\lambda_{\min} = 2,189$.

<i>Vía KEGG</i>	<i>Coefficiente LASSO</i>
<i>Adherens junction</i>	0,281
<i>Amyotrophic lateral sclerosis (ALS)</i>	-0,199
<i>Butanoate metabolism</i>	-0,547
<i>ECM receptor interaction</i>	-0,226
<i>Glycosaminoglycan biosynthesis - chondroitin sulfate</i>	-0,227
<i>Hematopoietic cell lineage</i>	-0,634
<i>MAPK signaling pathway</i>	-0,045
<i>Phosphatidylinositol signaling system</i>	-0,267
<i>Porphyrin and chlorophyll metabolism</i>	-0,648
<i>Viral myocarditis</i>	-0,102

Tras la regresión LASSO sobre esta nueva matriz en el conjunto de entrenamiento, se seleccionaron 10 vías con coeficiente distinto de cero (tabla 4). De ellas, una presentó un coeficiente positivo y 9 negativos. Las vías con mayor magnitud absoluta del coeficiente fueron la vía del linaje de células hematopoyéticas (-0,634), la vía del metabolismo de porfirinas y clorofilas (-0,649) y la vía del metabolismo de butanoato (-0,548).

5.5. Evaluación de los modelos predictivos

Se entrenaron y evaluaron tres algoritmos de aprendizaje automático -SVM con kernel lineal, SVM con kernel radial y Random Forest- sobre las tres modalidades de información ómica de este estudio: expresión génica, mutaciones somáticas y matriz integrada. El rendimiento de estos modelos se evaluó sobre el conjunto de prueba.

5.5.1. Modelos entrenados sobre los datos de expresión génica

Los modelos entrenados a partir de los genes diferencialmente expresados mostraron un rendimiento predictivo débil, con valores de AUC comprendidos entre 0,56 y 0,66 (tabla 5, figura 20). Aunque no muy por encima de los demás, el modelo SVM con kernel radial presentó el mayor AUC, con un intervalo de confianza al 95% que superó el valor de 0,5 por el límite inferior. No obstante, los tres modelos presentaron un IC amplio del AUC.

Tabla 5. Rendimiento de los modelos predictivos entrenados con datos de expresión génica. Hiperparámetros óptimos en cada modelo: SVM lineal: $C = 0,01$; SVM radial: $\sigma = 0,001$, $C = 2$; RF: $mtry = 50$

<i>Modelo</i>	<i>AUC (IC 95%)</i>	<i>Exactitud</i>	<i>Sensibilidad</i>	<i>Especificidad</i>	<i>Precisión</i>	<i>F1</i>
<i>SVM Lineal</i>	0,567 (0,373-0,76)	0,795	0,166	0,894	0,2	0,181
<i>SVM Radial</i>	0,663 (0,502-0,824)	0,84	0,25	0,934	0,375	0,3
<i>RF</i>	0,659 (0,49-0,827)	0,852	0,083	0,973	0,33	0,13

En cuanto a las métricas de clasificación, los 3 modelos mostraron una exactitud con valores comprendidos entre 0,79 y 0,85. No obstante, presentaron una sensibilidad limitada. El SVM radial fue el modelo que pudo predecir correctamente más observaciones de la clase positiva (Alto riesgo), con una sensibilidad del 25%.




Figura 20. Curvas ROC de los modelos predictivos entrenados sobre datos de expresión génica.

5.5.2. Modelos entrenados sobre los datos de mutaciones somáticas

Los modelos entrenados a partir de la información mutacional a nivel de vías biológicas mostraron una capacidad discriminativa limitada, con valores de AUC entre 0,55 y 0,62 e intervalos de confianza amplios (tabla 6, figura 21).

Tabla 6. Rendimiento de los modelos predictivos entrenados con datos de mutaciones somáticas agrupados por vía KEGG. Hiperparámetros óptimos en cada modelo: SVM lineal C=10 ; SVM radial: sigma = 0,12, C = 2; RF: mtry=2.

<i>Modelo</i>	<i>AUC (IC 95%)</i>	<i>Exactitud</i>	<i>Sensibilidad</i>	<i>Especificidad</i>	<i>Precisión</i>	<i>F1</i>
<i>SVM Lineal</i>	0,558 (0,267-0,699)	0,864	0	1	0	0
<i>SVM Radial</i>	0,624 (0,409-0,838)	0,864	0	1	0	0
<i>RF</i>	0,618 (0,464-0,772)	0,864	0	1	0	0

A pesar de los valores de exactitud de 0,86, ninguno de los modelos logró clasificar correctamente las observaciones de la clase positiva, donde presentaron una sensibilidad de 0. Como consecuencia, la precisión y la puntuación F1 de los modelos fueron igualmente 0.




Figura 21. Curvas ROC de los modelos predictivos entrenados sobre datos de vías KEGG alteradas.

5.5.3. Modelos entrenados sobre la matriz integrada

Tras la selección de variables específica para cada modalidad ómica, se construyó la matriz integrada concatenando los 499 transcritos diferencialmente expresados y las 10 vías de señalización KEGG seleccionadas mediante regresión LASSO, resultando en una matriz de 444 pacientes $\times$ 509 variables, que fue empleada como entrada para los modelos predictivos.

Los modelos entrenados con la matriz multi-ómica presentaron valores de AUC comprendidos entre 0,61 y 0,67 (tabla 7, figura 22). No se observó un aumento notable en los valores de AUC respecto a los modelos entrenados sobre los datos de expresión génica, presentando además intervalos de confianza amplios y solapados entre las dos modalidades.

SVM Lineal fue el único algoritmo que mejoró su sensibilidad respecto al modelo individual de expresión génica, alcanzando una sensibilidad de 0,41 y una precisión de 0,38.

Tabla 7. Rendimiento de los modelos predictivos entrenados con la matriz integrada.

Hiperparámetros óptimos en cada modelo: SVM lineal: C=1; SVM radial: sigma = 0,001, C = 2; RF: mtry=50.

<i>Modelo</i>	<i>AUC (IC 95%)</i>	<i>Exactitud</i>	<i>Sensibilidad</i>	<i>Especificidad</i>	<i>Precisión</i>	<i>F1</i>
<i>SVM Lineal</i>	0,618 (0,419-0,817)	0,83	0,416	0,894	0,384	0,4
<i>SVM Radial</i>	0,671 (0,505-0,836)	0,829	0,25	0,921	0,333	0,283
<i>RF</i>	0,646 (0,478-0,812)	0,84	0,083	0,96	0,25	0,12




Figura 22. Curvas ROC de los modelos predictivos entrenados sobre la matriz integrada.

6. Discusión

En este estudio, hemos evaluado la capacidad de distintos algoritmos de aprendizaje automático para clasificar a los pacientes con cáncer de mama según su supervivencia a tres años a partir de información transcriptómica y mutacional. En el conjunto de prueba, el mejor rendimiento correspondió al modelo SVM con kernel radial basado en la integración de ambas modalidades, que alcanzó un AUC de 0,671 y una sensibilidad de 0,25. Este resultado implica que el modelo identificó correctamente sólo 3 pacientes clasificados como Alto riesgo, en un conjunto de prueba que incluía 12 eventos. En líneas generales, estos resultados sitúan la capacidad discriminativa de los modelos desarrollados en un rango moderado y ponen de manifiesto las limitaciones de la aproximación empleada para identificar a los pacientes con supervivencia inferior a 3 años.

La definición de una variable de respuesta basada en la supervivencia a tres años a partir de los datos clínicos permitió transformar el problema de supervivencia en un problema de clasificación binaria, facilitando la aplicación de algoritmos de aprendizaje automático. No obstante, la dicotomización del tiempo de supervivencia presenta limitaciones intrínsecas ante la heterogeneidad del cáncer de mama. Los pacientes que superan el punto de corte quedan incluidos en el mismo grupo, independientemente de su supervivencia posterior; por el contrario, aquellos con tiempos próximos a los tres años pueden presentar características pronósticas similares pese a quedar asignados a grupos diferentes. Por tanto, la simplificación de la naturaleza continua del tiempo de supervivencia debe tenerse en cuenta a la hora de interpretar los resultados.

La caracterización exploratoria de los datos mostró patrones de expresión y alteraciones somáticas compatibles con las características moleculares descritas para el cáncer de mama (11,13). A nivel transcriptómico, se observaron diferencias globales en los perfiles de expresión asociadas al subtipo molecular. Esta separación fue evidente tanto en el análisis de componentes principales como en el mapa de calor sobre los genes más variables de la cohorte, donde los pacientes pertenecientes a los distintos subtipos mostraron patrones de

expresión específicos. Estos resultados son consistentes con el hecho de que el subtipo molecular del cáncer de mama constituye una de las fuentes de mayor variabilidad global de la expresión génica (14). Por el contrario, los dos grupos de supervivencia no mostraron separación en el espacio de mayor varianza, encontrándose ampliamente distribuidos a lo largo de las dos primeras componentes principales. Este resultado sugiere que las diferencias asociadas a la supervivencia no están capturadas por los genes con mayor variabilidad global. Asimismo, justifica la necesidad de realizar una selección específica de variables previa a los modelos predictivos para identificar aquellas características moleculares más correlacionadas con la variable respuesta.

El análisis de expresión diferencial permitió identificar diferencias significativas en la expresión génica entre los grupos de riesgo definidos según la supervivencia. Resulta de especial interés el agrupamiento de genes codificantes de los distintos segmentos de las inmunoglobulinas, que mostraron una menor expresión en los tumores con supervivencia inferior a 3 años. Algunos estudios asocian este patrón de expresión a una menor infiltración de células B en el tumor, lo que se traduce en una menor respuesta inmune antitumoral y, por tanto, menor supervivencia (43,44). No obstante, dado que el análisis no ajustó por variables como la edad, el estadio o el subtipo molecular -conocidos factores clínicos que afectan a la supervivencia- no puede descartarse que este patrón refleje el efecto de dichas covariables, por lo que los genes diferencialmente expresados deben interpretarse como variables asociadas a los grupos definidos en función de la supervivencia a tres años, no como marcadores independientes de supervivencia.

El análisis GSEA permitió evaluar si los cambios de expresión observados se concentraban en determinados procesos biológicos. La activación de vías de proliferación celular en el grupo con supervivencia inferior a 3 años, que incluyeron las dianas de E2F, las dianas de MYC y el punto de control G2/M, resulta especialmente relevante, pues el enriquecimiento de estas vías ha demostrado estar asociado a una peor supervivencia en cáncer de mama (45–47). E2F es un factor de transcripción que actúa en la transición G1/S del ciclo celular, mientras que MYC actúa también como activador transcripcional de genes implicados en

proliferación y crecimiento celular. Con las mismas consideraciones que en el párrafo anterior, estos hallazgos son consistentes con la biología conocida del cáncer de mama agresivo, aunque su interpretación como marcadores pronósticos independientes requeriría validación en modelos ajustados por covariables clínicas.

En cuanto al perfil mutacional, la quinasa *PIK3CA* y el gen supresor de tumores *TP53* dominaron el paisaje mutacional de la cohorte con las mayores frecuencias de alteración, seguidos por genes recurrentemente mutados en cáncer de mama como *GATA3*, *MAP3K1* o *CDH1*. Este patrón es consistente con numerosos estudios genómicos de caracterización del cáncer de mama (13,16,48). No obstante, más allá de los genes principales, el paisaje mutacional del cáncer de mama se caracteriza por una gran diversidad genética, impulsada por un elevado número de genes conductores del cáncer con baja frecuencia poblacional (48,49). De acuerdo con dicha heterogeneidad, en esta cohorte se identificaron casi 9 000 genes mutados, muchos de ellos presentes en muy pocos pacientes. Como consecuencia, la matriz binaria presentó una elevada dispersión, lo que supuso una dificultad para la utilización de las mutaciones individuales como variables predictoras en los modelos de aprendizaje automático.

Ante esta dispersión, se exploró una representación alternativa de la información mutacional mediante su agregación a nivel de vías biológicas. De este modo, alteraciones diferentes que afectan a componentes de una misma vía se asocian a una única variable predictora, reduciendo potencialmente la dispersión de la matriz y facilitando la identificación de señales biológicas compartidas. Sin embargo, aunque LASSO permitió seleccionar un conjunto de vías candidatas como variables predictoras, los modelos predictivos basados en esta modalidad no lograron clasificar correctamente a los pacientes del grupo de alto riesgo, obteniéndose una sensibilidad nula en todos los algoritmos evaluados. Por tanto, en esta cohorte y bajo la estrategia de modelado empleada, la capacidad de la información mutacional para clasificar correctamente a los pacientes con menor supervivencia fue limitada.

Ante estos resultados, el marcado desequilibrio entre las clases del conjunto de prueba debe tenerse en cuenta para la interpretación de las métricas de rendimiento. De los 88 pacientes de este conjunto, 76 pertenecían a la clase Bajo riesgo y únicamente 12 a Alto riesgo. En consecuencia, un clasificador que asignase sistemáticamente todos los pacientes a la clase mayoritaria alcanzaría una exactitud de 76/88 (86,4%) sin identificar ningún paciente de alto riesgo. De hecho, este mismo escenario ocurrió con los modelos mutacionales, que alcanzaron dichos valores de exactitud pese a presentar una sensibilidad nula. Por ello, en este contexto la exactitud global resulta poco informativa y debe otorgarse mayor importancia a métricas como la sensibilidad, la precisión y la puntuación F1, junto con el AUC-ROC, para evaluar la capacidad de los modelos de identificar correctamente ambas clases.

Por otro lado, los modelos basados en datos de expresión génica presentaron una sensibilidad reducida pero no nula, con valores comprendidos entre el 8% y el 25% según el algoritmo. Aunque estos resultados indican que algunos pacientes con supervivencia inferior a 3 años fueron clasificados correctamente, el número de eventos detectados siguió siendo reducido. Las estimaciones puntuales de AUC fueron similares a las observadas con el resto de aproximaciones, por lo que, en esta partición de los datos, no puede afirmarse una ventaja clara de esta modalidad. No obstante, el comportamiento observado es compatible con el potencial valor de la información transcriptómica para la estratificación pronóstica en cáncer de mama (11,18).

La integración de ambas modalidades ómicas no produjo una mejora respecto al modelo basado exclusivamente en expresión génica. El mejor resultado correspondió al SVM con kernel radial integrado, con un AUC de 0,671, frente a 0,663 para el modelo basado exclusivamente en expresión. La diferencia entre ambas estimaciones es mínima, además, los intervalos de confianza fueron amplios y solapados. Por tanto, estos resultados no permiten considerar que la incorporación de la información mutacional en esta partición haya proporcionado una mejora clara del rendimiento predictivo.

Este resultado no implica necesariamente que la información mutacional carezca de utilidad pronóstica, sino que su incorporación mediante la estrategia de integración empleada en este estudio no proporcionó información predictiva adicional suficiente para mejorar el modelo transcriptómico. Estudios previos, como el de He *et al.* (2021), han demostrado que la incorporación de información mutacional puede mejorar la predicción de supervivencia en cáncer de mama (50). Sin embargo, dicho estudio emplea metodología diferente en cuanto a la estrategia de selección de variables e integración, basada en mRMR (*Minimum Redundancy Feature Selection*) y en un modelo de *multiple kernel learning* (MKL).

En el presente estudio se utilizó una estrategia de integración temprana basada en la concatenación de las variables seleccionadas de ambas modalidades. Aunque este procedimiento presenta la ventaja de su sencillez, puede incrementar la dimensionalidad del espacio de predictores y no tiene en cuenta las diferencias en la naturaleza y distribución de las distintas modalidades (51). En este contexto, la incorporación de un número reducido de variables mutacionales a un conjunto de predictores mayoritariamente transcriptómicos no implica necesariamente que dicha adición produzca una mejora en la discriminación de los pacientes.

En síntesis, la interpretación de estos resultados debe realizarse teniendo en cuenta varias limitaciones del estudio, desarrollados en el apartado 8. En particular, el reducido número de eventos en el conjunto de prueba limita la precisión de las estimaciones de rendimiento, mientras que el uso de una única partición entrenamiento-prueba y la ausencia de una validación externa dificultan valorar la estabilidad y generalización de los modelos. Asimismo, la exclusión de 521 pacientes por seguimiento insuficiente redujo el tamaño de la cohorte disponible, y la no inclusión de variables clínicas como predictores impidió evaluar el posible valor complementario de la información molecular respecto a los factores clínicos conocidos. Estas limitaciones condicionan el alcance de las conclusiones obtenidas y constituyen aspectos que deberían abordarse en estudios posteriores.

7. Conclusiones

A partir de los resultados obtenidos en este trabajo y en base a los objetivos expuestos, se pueden extraer las siguientes conclusiones:

- Se han obtenido y procesado los datos clínicos, transcriptómicos y de mutaciones somáticas procedentes del proyecto TCGA-BRCA, estableciendo un flujo de trabajo reproducible que abarca desde el preprocesamiento de los datos hasta la selección de características y el entrenamiento de modelos de aprendizaje automático. Los datos clínicos permitieron caracterizar la cohorte y construir la variable de respuesta basada en la supervivencia a tres años.
- La definición de una variable respuesta basada en la supervivencia a 3 años permitió dividir la cohorte en dos grupos definidos como Alto riesgo y Bajo riesgo. Sin embargo, el reducido número de pacientes pertenecientes al grupo de alto riesgo constituye una limitación importante para la construcción y evaluación de los modelos predictivos.
- La representación de las alteraciones mutacionales a nivel de vías biológicas permite reducir la dispersión inherente a la matriz de mutaciones a nivel de gen. Sin embargo, esta estrategia mostró una sensibilidad insuficiente en el conjunto de prueba.
- Los modelos basados en expresión génica y el modelo integrado obtuvieron AUC similares en el conjunto de prueba analizado, sin observarse una ventaja clara de una aproximación sobre la otra bajo las condiciones del estudio. En consecuencia, la hipótesis de que la integración multi-ómica mejoraría el rendimiento predictivo no queda respaldada en las condiciones y estrategia de integración evaluadas en este estudio.

En conjunto, este trabajo proporciona un análisis exploratorio y una comparación metodológica de diferentes estrategias de modelado para la clasificación de pacientes

según su supervivencia a tres años. No obstante, la evaluación de su potencial pronóstico requeriría de validación externa en cohortes independientes.

8. Limitaciones del estudio

El presente trabajo presenta una serie de limitaciones metodológicas que deben tenerse en cuenta en la interpretación de los resultados y abordarse en estudios posteriores. En primer lugar, el reducido número de pacientes pertenecientes al grupo de alto riesgo ($n=64$) y el marcado desequilibrio entre clases (proporción aproximada de 6:1) constituyeron una de las principales limitaciones del estudio, condicionando tanto el entrenamiento como la evaluación de los modelos predictivos y dificultando la correcta identificación de la clase minoritaria. Estrategias como el ajuste de pesos de clase podrían ayudar a mitigar este efecto.

En segundo lugar, la variable de respuesta se construyó a partir de un único umbral temporal de supervivencia (3 años), lo que implicó la exclusión de 521 pacientes de la cohorte inicial por falta de seguimiento suficiente.

En tercer lugar, las variables clínicas se utilizaron para la caracterización de la cohorte y la definición de la variable respuesta, pero no se incorporaron como predictores en los modelos ni se utilizaron para ajustar los análisis de expresión diferencial y enriquecimiento génico. Por tanto, no puede descartarse que parte de las diferencias transcriptómicas observadas reflejen el efecto de covariables como la edad, el estadio o el subtipo molecular. De la misma forma, no se puede evaluar si la información molecular aporta valor predictivo adicional respecto a estas variables, por lo que los resultados deben interpretarse como una evaluación del potencial de las características moleculares de forma aislada.

En relación a la evaluación de los modelos, aunque se empleó validación cruzada estratificada repetida durante el entrenamiento, el rendimiento final se evaluó sobre una única partición fija de entrenamiento y prueba, por lo que las estimaciones de rendimiento pueden depender en gran medida de la composición de dicha partición. Además, no se realizó una validación externa en una cohorte independiente, necesaria para evaluar la generalización de los modelos a nuevas poblaciones.

Finalmente, la estrategia de integración temprana empleada combina datos de expresión génica y variables binarias de mutaciones somáticas agregadas por vías, que presentan diferente naturaleza y distribución. Otras estrategias de integración podrían representar de forma diferente la información complementaria de ambas modalidades.

Referencias bibliográficas

1. Bray F, Laversanne M, Sung H, Ferlay J, Siegel RL, Soerjomataram I, et al. Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA Cancer J Clin*. 1 de mayo de 2024;74(3):229-63. doi:10.3322/CAAC.21834;REQUESTEDJOURNAL:JOURNAL:15424863;WGROUPE:STRING:PUBLICATION PubMed PMID: 38572751.
2. Harbeck N, Penault-Llorca F, Cortes J, Gnant M, Houssami N, Poortmans P, et al. Breast cancer. *Nat Rev Dis Primers*. 2019;5(1):66. doi:10.1038/s41572-019-0111-2
3. Riggio AI, Varley KE, Welm AL. The lingering mysteries of metastatic recurrence in breast cancer. *Br J Cancer*. 2021;124(1):13-26. doi:10.1038/s41416-020-01161-4
4. Huang S, Yang J, Fong S, Zhao Q. Artificial intelligence in cancer diagnosis and prognosis: Opportunities and challenges. *Cancer Lett*. 28 de febrero de 2020;471:61-71. doi:10.1016/J.CANLET.2019.12.007 PubMed PMID: 31830558.
5. ¿Qué es el cáncer y cómo se desarrolla? - SEOM: Sociedad Española de Oncología Médica © 2019 [Internet]. [citado 27 de mayo de 2026]. Disponible en: <https://seom.org/informacion-sobre-el-cancer/que-es-el-cancer-y-como-se-desarrolla?showall=1&start=0>
6. Nolan E, Lindeman GJ, Visvader JE. Deciphering breast cancer: from biology to the clinic. *Cell*. 13 de abril de 2023;186(8):1708-28. doi:10.1016/j.cell.2023.01.040
7. Biswas SK, Banerjee S, Baker GW, Kuo CY, Chowdhury I. The Mammary Gland: Basic Structure and Molecular Signaling during Development. *Int J Mol Sci*. 2022;23(7). doi:10.3390/ijms23073883
8. Guo L, Kong D, Liu J, Zhan L, Luo L, Zheng W, et al. Breast cancer heterogeneity and its implication in personalized precision therapy. *Exp Hematol Oncol*. 1 de diciembre de 2023;12(1):3. doi:10.1186/S40164-022-00363-1 PubMed PMID: 36624542.

9. Feng Y, Spezia M, Huang S, Yuan C, Zeng Z, Zhang L, et al. Breast cancer development and progression: Risk factors, cancer stem cells, signaling pathways, genomics, and molecular pathogenesis. *Genes Dis.* 2018;5(2):77-106. doi:<https://doi.org/10.1016/j.gendis.2018.05.001>
10. Weigelt B, Reis-Filho JS. Histological and molecular types of breast cancer: is there a unifying taxonomy? *Nature Reviews Clinical Oncology* 2009 6:12. 2009;6(12):718-30. doi:10.1038/nrclinonc.2009.166 PubMed PMID: 19942925.
11. Perou CM, Sørile T, Eisen MB, Van De Rijn M, Jeffrey SS, Ress CA, et al. Molecular portraits of human breast tumours. *Nature*. 17 de agosto de 2000;406(6797):747-52. doi:10.1038/35021093 PubMed PMID: 10963602.
12. Prat A, Pineda E, Adamo B, Galván P, Fernández A, Gaba L, et al. Clinical implications of the intrinsic molecular subtypes of breast cancer. *Breast*. 1 de noviembre de 2015;24:S26-35. doi:10.1016/j.breast.2015.07.008 PubMed PMID: 26253814.
13. Koboldt DC, Fulton RS, McLellan MD, Schmidt H, Kalicki-Veizer J, McMichael JF, et al. Comprehensive molecular portraits of human breast tumours. *Nature* 2012 490:7418. 23 de septiembre de 2012;490(7418):61-70. doi:10.1038/nature11412 PubMed PMID: 23000897.
14. Hoadley KA, Fabrice A, Ellis MJ, Perou CM. Breast cancer intrinsic subtypes [Internet]. 2014 [citado 3 de junio de 2026]. Disponible en: https://www.nature.com/documents/nrclinonc_posters_breastcancer.pdf
15. Sørle T, Perou CM, Tibshirani R, Aas T, Geisler S, Johnsen H, et al. Gene expression patterns of breast carcinomas distinguish tumor subclasses with clinical implications. *Proc Natl Acad Sci U S A*. 11 de septiembre de 2001;98(19):10869. doi:10.1073/PNAS.191367098 PubMed PMID: 11553815.
16. Nik-Zainal S, Davies H, Staaf J, Ramakrishna M, Glodzik D, Zou X, et al. Landscape of somatic mutations in 560 breast cancer whole-genome sequences. *Nature*. 2 de

mayo de 2016;534(7605):47-54. doi:10.1038/NATURE17676 PubMed PMID: 27135926.

17. Al-Mahmood S, Sapiezynski J, Garbuzenko OB, Minko T. Metastatic and triple-negative breast cancer: challenges and treatment options. *Drug Deliv Transl Res*. 2018;8(5):1483-507. doi:10.1007/s13346-018-0551-3
18. Min N, Wei Y, Zheng Y, Li X. Advancement of prognostic models in breast cancer: a narrative review. *Gland Surg*. 2021;10(9):2815831-2812831. doi:10.21037/GS-21-441
19. Łukasiewicz S, Czezelewski M, Forma A, Baj J, Sitarz R, Stanisławek A. Breast Cancer—Epidemiology, Risk Factors, Classification, Prognostic Markers, and Current Treatment Strategies—An Updated Review. *Cancers* 2021, Vol 13, Page 4287. 25 de agosto de 2021;13(17):4287. doi:10.3390/CANCERS13174287 PubMed PMID: 34503097.
20. Qin D. Next-generation sequencing and its clinical application. *Cancer Biol Med*. 2019;16(1):4. doi:10.20892/J.ISSN.2095-3941.2018.0055 PubMed PMID: 31119042.
21. Sahoo OS, Aidasani H, Nayek A, Tripathi S, Talukdar J, Gul A, et al. Role of next-generation sequencing in revolutionizing healthcare for cancer management. *MedComm - Future Medicine*. 1 de diciembre de 2024;3(4):e70001. doi:10.1002/MEF2.70001;SUBPAGE:STRING:FULL
22. Satam H, Joshi K, Mangrolia U, Waghoo S, Zaidi G, Rawool S, et al. Next-Generation Sequencing Technology: Current Trends and Advancements. *Biology* 2023, Vol 12, Page 997. 13 de julio de 2023;12(7):997. doi:10.3390/BIOLOGY12070997 PubMed PMID: 37508427.
23. Cieřlik M, Chinnaiyan AM. Cancer transcriptome profiling at the juncture of clinical translation. *Nat Rev Genet*. 1 de febrero de 2017;19(2):93-109. doi:10.1038/NRG.2017.96 PubMed PMID: 29279605.

24. de Anda-Jáuregui G, Hernández-Lemus E. Computational Oncology in the Multi-Omics Era: State of the Art. *Front Oncol*. 7 de abril de 2020;10:516519. doi:10.3389/FONC.2020.00423/FULL
25. Tomczak K, Czerwińska P, Wiznerowicz M. The Cancer Genome Atlas (TCGA): an immeasurable source of knowledge. *Contemp Oncol (Pozn)*. 2015;19(1A):A68-77. doi:10.5114/WO.2014.47136 PubMed PMID: 25691825.
26. The Cancer Genome Atlas Program (TCGA) - NCI [Internet]. [citado 5 de julio de 2026]. Disponible en: <https://www.cancer.gov/ccg/research/genome-sequencing/tcga>
27. Genomic Data Commons | CRDC [Internet]. [citado 5 de julio de 2026]. Disponible en: <https://datacommons.cancer.gov/repository/genomic-data-commons>
28. Chang TG, Park S, Schäffer AA, Jiang P, Ruppin E. Hallmarks of artificial intelligence contributions to precision oncology. *Nature Cancer* 2025 6:3. 7 de marzo de 2025;6(3):417-31. doi:10.1038/s43018-025-00917-2 PubMed PMID: 40055572.
29. Huang S, Yang J, Fong S, Zhao Q. Artificial intelligence in cancer diagnosis and prognosis: Opportunities and challenges. *Cancer Letters*. Elsevier Ireland Ltd; 2020. p. 61-71. doi:10.1016/j.canlet.2019.12.007 PubMed PMID: 31830558.
30. Zhang B, Shi H, Wang H. Machine Learning and AI in Cancer Prognosis, Prediction, and Treatment Selection: A Critical Approach. *Journal of Multidisciplinary Healthcare*. Dove Medical Press Ltd; 2023. p. 1779-91. doi:10.2147/JMDH.S410301
31. Owotogbe J, Oyekanmi E, Adepoju SE, Akinsunmade AE. Machine learning and deep learning for breast cancer: A decade systematic review of detection, classification, prognosis, and explainability. *Inform Med Unlocked*. 1 de junio de 2026;63:101756. doi:10.1016/J.IMU.2026.101756
32. Fan C, Prat A, Parker JS, Liu Y, Carey LA, Troester MA, et al. Building prognostic models for breast cancer patients using clinical variables and hundreds of gene expression

- signatures. *BMC Medical Genomics* 2011 4:1. 9 de enero de 2011;4(1):3-. doi:10.1186/1755-8794-4-3 PubMed PMID: 21214954.
33. Sammut SJ, Crispin-Ortuzar M, Chin SF, Provenzano E, Bardwell HA, Ma W, et al. Multi-omic machine learning predictor of breast cancer therapy response. *Nature*. 27 de enero de 2022;601(7894):623-9. doi:10.1038/s41586-021-04278-5 PubMed PMID: 34875674.
34. Nguyen R, Vafaee F. Multi-omics prognostic marker discovery and survival modelling: a case study on multi-cancer survival analysis of women's specific tumours. *Sci Rep*. 1 de diciembre de 2025;15(1). doi:10.1038/s41598-025-20572-y PubMed PMID: 41120506.
35. Nikolaou N, Salazar D, RaviPrakash H, Gonçalves M, Mulla R, Burlutskiy N, et al. A machine learning approach for multimodal data fusion for survival prediction in cancer patients. *NPJ Precis Oncol*. 1 de diciembre de 2025;9(1). doi:10.1038/s41698-025-00917-6
36. Arya N, Saha S, Mathur A, Saha S. Improving the robustness and stability of a machine learning model for breast cancer prognosis through the use of multi-modal classifiers. *Sci Rep*. 1 de diciembre de 2023;13(1). doi:10.1038/s41598-023-30143-8 PubMed PMID: 36906618.
37. Do TTN, Block I, Burton M, Sørensen KP, Larsen MJ, Jylling AMB, et al. Multi-transcriptomics predicts clinical outcome in systemically untreated breast cancer patients with extensive follow-up. *Breast Cancer Research*. 1 de diciembre de 2025;27(1). doi:10.1186/s13058-025-02061-2 PubMed PMID: 40665339.
38. Zhang H, Yang F, Xu Y, Zhao S, Jiang YZ, Shao ZM, et al. Multimodal integration using a machine learning approach facilitates risk stratification in HR+/HER2- breast cancer. *Cell Rep Med*. 18 de febrero de 2025;6(2). doi:10.1016/j.xcrm.2024.101924 PubMed PMID: 39848244.

39. Dobin A, Davis CA, Schlesinger F, Drenkow J, Zaleski C, Jha S, et al. STAR: ultrafast universal RNA-seq aligner. *Bioinformatics*. enero de 2013;29(1):15-21. doi:10.1093/BIOINFORMATICS/BTS635 PubMed PMID: 23104886.
40. Love MI, Anders S, Huber W. Analyzing RNA-seq data with DESeq2 [Internet]. 2026 [citado 16 de agosto de 2026]. Disponible en: <https://bioconductor.org/packages/release/bioc/vignettes/DESeq2/inst/doc/DESeq2.html>
41. Mayakonda A, Lin DC, Assenov Y, Plass C, Koeffler HP. Maftools: Efficient and comprehensive analysis of somatic variants in cancer. *Genome Res*. 1 de noviembre de 2018;28(11):1747-56. doi:10.1101/GR.239244.118/-/DC1 PubMed PMID: 30341162.
42. Shyr C, Tarailo-Graovac M, Gottlieb M, Lee JJY, Van Karnebeek C, Wasserman WW. FLAGS, frequently mutated genes in public exomes. *BMC Med Genomics*. 2014;7(1):64. doi:10.1186/S12920-014-0064-Y PubMed PMID: 25466818.
43. Hsu HM, Chu CM, Chang YJ, Yu JC, Chen CT, Jian CE, et al. Six novel immunoglobulin genes as biomarkers for better prognosis in triple-negative breast cancer by gene co-expression network analysis. *Scientific Reports* 2019 9:1. 14 de marzo de 2019;9(1):4484-. doi:10.1038/s41598-019-40826-w PubMed PMID: 30872752.
44. Angelats L, Paré L, Rubio-Perez C, Sanfeliu E, González A, Seguí E, et al. Linking tumor immune infiltration to enhanced longevity in recurrence-free breast cancer. *ESMO Open*. 1 de enero de 2025;10(1):104109. doi:10.1016/J.ESMOOP.2024.104109 PubMed PMID: 39765189.
45. Schulze A, Oshi M, Endo I, Takabe K. MYC Targets Scores Are Associated with Cancer Aggressiveness and Poor Survival in ER-Positive Primary and Metastatic Breast Cancer. *Int J Mol Sci*. 1 de noviembre de 2020;21(21):8127. doi:10.3390/IJMS21218127 PubMed PMID: 33143224.

46. Oshi M, Takahashi H, Tokumaru Y, Yan L, Rashid OM, Matsuyama R, et al. G2M Cell Cycle Pathway Score as a Prognostic Biomarker of Metastasis in Estrogen Receptor (ER)-Positive Breast Cancer. *International Journal of Molecular Sciences* 2020, Vol 21, Page 2921. 22 de abril de 2020;21(8):2921. doi:10.3390/IJMS21082921 PubMed PMID: 32331421.
47. ED N, MG B, R W, T I, K T. High EIF4EBP1 expression reflects mTOR pathway activity and cancer cell proliferation and is a biomarker for poor breast cancer prognosis. *Am J Cancer Res.* 2024;14(1):227-42. doi:10.62347/MTSD6746 PubMed PMID: 38323277.
48. Stephens PJ, Tarpey PS, Davies H, Van Loo P, Greenman C, Wedge DC, et al. The landscape of cancer genes and mutational processes in breast cancer. *Nature.* 21 de junio de 2012;486(7403):400. doi:10.1038/NATURE11017 PubMed PMID: 22722201.
49. Yates LR, Desmedt C. Translational Genomics: Practical Applications of the Genomic Revolution in Breast Cancer. *Clinical Cancer Research.* 1 de junio de 2017;23(11):2630-9. doi:10.1158/1078-0432.CCR-16-2548 PubMed PMID: 28572257.
50. He Z, Zhang J, Yuan X, Zhang Y. Integrating Somatic Mutations for Breast Cancer Survival Prediction Using Machine Learning Methods. *Front Genet.* 18 de enero de 2021;11. doi:10.3389/FGENE.2020.632901 PubMed PMID: 33537063.
51. Picard M, Scott-Boyer MP, Bodein A, Périn O, Droit A. Integration strategies of multi-omics data for machine learning analysis. *Comput Struct Biotechnol J.* 1 de enero de 2021;19:3735-46. doi:10.1016/J.CSBJ.2021.06.030;WEBSITE:WEBSITE:SPJ-SITE;WGROUPE:STRING:PUBLICATION